

8. fejezet

Szélsőértékszámítás

Egy- és többváltozós függvények lokális szélsőértékei keresésével foglalkozunk ebben a fejezetben. Elegendő csak minimumkeresési módszereket vizsgálni, mivel egy $f(x)$ függvény ott veszi fel a maximumát, ahol a $-f(x)$ függvény a minimumát, így a maximum keresés mindig visszavezethető minimum keresésre.

Algoritmusoknak három nagy csoportjával foglalkozunk: deriváltat nem használó, csak első deriváltat használó és első és második deriváltat is igénylő módszerekkel. Az első csoportba tartozik az aranymetszés szerinti keresés, a simplex és a Nelder–Mead-módszer, a másodikba a gradiens módszer, a harmadikba pedig a Newton-módszer. Ez utóbbi csoportba sorolhatók talán a kvázi-Newton módszerek is, melyek nem a pontos derivált és második derivált értéket használják, hanem annak valamilyen közelítését.

8.1. Analízis előismeretek

8.1. tétel. Legyen $f: \mathbb{R}^n \rightarrow \mathbb{R}$ parciálisan differenciálható minden változója szerint. Ekkor ha f -nek létezik lokális szélsőértéke az $\mathbf{a}$ pontban, akkor $\frac{\partial f(\mathbf{a})}{\partial x_i} = 0$ teljesül minden $i = 1, \dots, n$ -re.

Ha $f \in C^2$, és valamely $\mathbf{a}$ pontban $f'(\mathbf{a}) = \mathbf{0}$, továbbá az $f''(\mathbf{a})$ Hesse-mátrix pozitív (negatív) definit, akkor f -nek lokális minimuma (maximuma) van $\mathbf{a}$ -ban.

Kétváltozós függvényekre az előbbi tétel speciális esetekén kapjuk:

8.2. tétel. Legyen $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $f \in C^2$. Ekkor ha f -nek létezik lokális szélsőértéke az (a, b) pontban, akkor


$$\frac{\partial f}{\partial x}(a, b) = 0, \quad \frac{\partial f}{\partial y}(a, b) = 0 \quad (8.1)$$

teljesül.

Fordítva, ha valamely (a, b) -re (8.1) teljesül, továbbá

$$D(a, b) := \frac{\partial^2 f}{\partial x^2}(a, b) \cdot \frac{\partial^2 f}{\partial y^2}(a, b) - \left(\frac{\partial^2 f}{\partial x \partial y}(a, b) \right)^2 > 0$$

akkor f -nek létezik lokális szélsőértéke (a, b) -ben, mégpedig lokális maximuma, ha $\frac{\partial^2 f}{\partial x^2}(a, b) < 0$ ill. lokális minimuma, ha $\frac{\partial^2 f}{\partial x^2}(a, b) > 0$. Ha $D(a, b) < 0$, akkor f -nek nincs szélsőértéke (a, b) -ben.




8.1. ábra. Unimodális függvények

8.2. Aranymetszés szerinti keresés módszere

Legyen $f: [a, b] \rightarrow \mathbb{R}$ folytonos, és feltesszük, hogy f *unimodális*, azaz f -nek egyértelmű lokális minimuma van $[a, b]$ -ben. Ez teljesül pl. ha a függvény konvex az $[a, b]$ intervallumon, de a konvexitás nem szükséges ahhoz, hogy egy függvény unimodális legyen (lásd például a 8.1. ábrán szereplő második és harmadik függvényt). Jelölje p az f függvény minimumhelyét.

Az *aranymetszés szerinti keresés módszerénél*, az intervallumfelezés módszeréhez hasonlóan, egyre szűkebb és szűkebb intervallumokra határoljuk be a függvény minimumhelyét: Legyen $a < y < x < b$. Ha $f(x) > f(y)$, akkor $p \in [a, x]$, ellenkező esetben $p \in [y, b]$ teljesül. (Lásd a 8.2. ábrát!) Ezután az $[a, x]$ illetve $[y, b]$ intervallummal folytatjuk az eljárást.




8.2. ábra.

Az x és y pontokat úgy választjuk, hogy az $[a, x]$ és $[y, b]$ intervallum hossza azonos legyen: $x - a = b - y = r(b - a)$ valamely $0 < r < 1$ -re. Ekkor

$$x = a + r(b - a), \quad y = a + (1 - r)(b - a) \quad (8.2)$$

alakú. Az $x > y$ feltételből kapjuk, hogy $0.5 < r < 1$ kell legyen. Jelölje $[a', b']$ a következő intervallumot. Válasszuk az új osztópontokat, x' -t és y' -t a (8.2) szabály szerint, és $f(x')$ és $f(y')$ összehasonlításával határozzuk meg a következő intervallumot. Még nem definiáltuk r -t. Az aranymetszés szerinti keresés módszere úgy választja meg r -t, hogy az új x' , y' osztópontok közül az egyik egyezzen meg egy előző osztóponttal, azért hogy minden lépésben csak egy új függvényértéket kelljen kiértékelni.

A 8.3. ábrán azt az esetet tüntettük fel, ahol a jobb oldali, $[y, b]$ intervallumba esik a minimumhely. Ekkor azt követeljük meg az osztópontok választásától, hogy $y' = x$ legyen. Ekkor



8.3. ábra.

teljesülnek a következő összefüggések:

$$\begin{aligned}
 a + r(b - a) &= y' \\
 &= a' + (1 - r)(b' - a') \\
 &= y + (1 - r)(b - y) \\
 &= a + (1 - r)(b - a) + (1 - r)(b - a - (1 - r)(b - a)),
 \end{aligned}$$

és így

$$r = 1 - r + (1 - r)(1 - (1 - r)),$$

amiből

$$r^2 + r - 1 = 0 \tag{8.3}$$

következik. Ennek pozitív megoldása $r = (\sqrt{5} - 1)/2 \approx 0.61834$. Ez az aranymetszés arányossági tényezője: r teljesíti az

$$\frac{r}{1 - r} = \frac{1}{r}$$

egyenlet.

Abban az esetben, amikor az $[a, x]$ intervallumban van a minimumhely, akkor úgy választjuk x', y' -t, hogy $x' = y$ legyen. Megmutatható (3. feladat), hogy ez a követelmény is a (8.3) egyenlethez vezet.

8.3. algoritmus. Aranymetszés szerinti keresés módszere

INPUT: $f(x)$,
 $[a, b]$,
 ε , - tolerancia
 OUTPUT: p - a minimumhely közelítése

```

 $r \leftarrow (\sqrt{5} - 1)/2$ 
 $x \leftarrow a + r(b - a)$ 
 $y \leftarrow a + (1 - r)(b - a)$ 
 $fx \leftarrow f(x)$ 
 $fy \leftarrow f(y)$ 
while  $(b - a) > \varepsilon$  do
  if  $fx > fy$  do
     $b \leftarrow x$ 
     $x \leftarrow y$ 
     $fx \leftarrow fy$ 
     $y \leftarrow a + (1 - r)(b - a)$ 
     $fy \leftarrow f(y)$ 
  else do
     $a \leftarrow y$ 

```

```

    y ← x
    fy ← fx
    x ← a + r(b - a)
    fx ← f(x)
  end do
end do
output((a + b)/2)

```

Könnyen igazolható a következő tétel:

8.4. tétel. Legyen $f \in C(a, b)$ unimodális függvény. Ekkor az arany metszés szerinti keresés módszere konvergál az f függvény minimumhelyéhez.

Könnyű ellenőrizni, hogy az arany metszés szerinti keresés módszere n lépése után az intervallum hossza $(b - a)r^n$ lesz. Így a 8.3. algoritmus az ε tolerancia értéket

$$n \geq \frac{\log \frac{\varepsilon}{b-a}}{\log r} \quad (8.4)$$

lépésben éri el.

8.5. példa. Keressük meg az $f(x) = x^2 - 0.8x + 1$ függvény minimumhelyét! Könnyű kiszámolni, hogy a függvény a minimumát a $p = 0.4$ pontban veszi fel. A 8.3. algoritmust alkalmaztuk az adott függvényre a $[-1, 2]$ kezdeti intervallumot és az $\varepsilon = 0.005$ tolerancia értéket használva, amelynek eredménye a 8.1. táblázatban látható. A (8.4) formula szerint $n \geq 13.29337586$ lépés kell az előírt tolerancia eléréséhez. A minimumhely az utolsó lépésben kapott $[0.3977741449, 0.4013328688]$ intervallumban helyezkedik el, a 8.3. algoritmus az intervallum felezőpontját, 0.3995535068-t adja meg, mint közelítő értéket. $\square$

8.1. táblázat. Arany metszés szerinti keresés módszere, $f(x) = x^2 - 0.8x + 1$

k	$[a_k, b_k]$	y_k	x_k
0	$[-1.0000000000, 2.0000000000]$	0.1458980338	0.8541019662
1	$[-1.0000000000, 0.8541019662]$	-0.2917960675	0.1458980338
2	$[-0.2917960675, 0.8541019662]$	0.1458980338	0.4164078650
3	$[0.1458980338, 0.8541019662]$	0.4164078650	0.5835921350
4	$[0.1458980338, 0.5835921350]$	0.3130823038	0.4164078650
5	$[0.3130823038, 0.5835921350]$	0.4164078650	0.4802665738
6	$[0.3130823038, 0.4802665738]$	0.3769410125	0.4164078650
7	$[0.3769410125, 0.4802665738]$	0.4164078650	0.4407997213
8	$[0.3769410125, 0.4407997213]$	0.4013328688	0.4164078650
9	$[0.3769410125, 0.4164078650]$	0.3920160087	0.4013328688
10	$[0.3920160087, 0.4164078650]$	0.4013328688	0.4070910050
11	$[0.3920160087, 0.4070910050]$	0.3977741449	0.4013328688
12	$[0.3977741449, 0.4070910050]$	0.4013328688	0.4035322811
13	$[0.3977741449, 0.4035322811]$	0.3999735572	0.4013328688
14	$[0.3977741449, 0.4013328688]$	0.3991334565	0.3999735572

Feladatok

1. Az arany metszés szerinti keresés módszerét alkalmazva keresse meg az alábbi függvények minimumhelyét az adott intervallumon:

- (a) $f(x) = x^3 - 3x + 1$, $x \in [-1, 2]$, (b) $f(x) = |\cos x|$, $x \in [0, 2]$,
(c) $f(x) = 1 - 10xe^{-x}$, $x \in [0, 2]$, (d) $f(x) = \cos(x^2 - x)$, $x \in [1, 3]$.

2. Alkalmazza az aranymetszés szerinti keresés módszerét az $f(x) = -1/x^2$ függvényre a $[-1, 1]$ intervallumon! Mit tapasztal?
3. Igazolja, hogy az $[a', b'] = [a, x]$ választáskor az $x' = y$ egyenlet akkor teljesül, ha r megoldása a (8.3) egyenletnek!
4. Bizonyítsa be a 8.4. tételt!
5. Ellenőrizze a (8.4) formulát!

8.3. Szimplex módszer

Egy n -dimenziós *szimplex*en olyan $n + 1$ darab n -dimenziós vektor konvex burkát, azaz az

$$\{\alpha_0 \mathbf{x}^{(0)} + \cdots + \alpha_n \mathbf{x}^{(n)} : 0 \leq \alpha_i \leq 1, \quad \alpha_0 + \cdots + \alpha_n \leq 1\}$$

halmazt értjük, ahol az $\mathbf{x}_1 - \mathbf{x}_0, \mathbf{x}_2 - \mathbf{x}_0, \dots, \mathbf{x}_n - \mathbf{x}_0$ vektorok lineárisan függetlenek. Ekkor az $\mathbf{x}^{(0)}, \dots, \mathbf{x}^{(n)}$ vektorokat a szimplex csúspontjainak hívjuk. Egydimenziós szimplexek a szakaszok, kétdimenziós szimplexek a háromszögek, háromdimenziós szimplexek pedig a tetraéderek.

A *szimplex módszert* n -változós függvények minimumhely keresésére használjuk. Vegyünk fel kiindulásként egy n -dimenziós szimplexet. Keressük meg, hogy melyik a „legrosszabb” csúspont, azaz melyik csúspontban veszi fel az f függvény a legnagyobb értéket. Legyen ez például az $\mathbf{x}^{(j)}$ pont. Ekkor a szimplex legrosszabb pontját tükrözzük az $\mathbf{x}^{(j)}$ ponttal szemben fekvő oldal középpontjára, azaz a többi csúspont

$$\mathbf{x}_c := \frac{1}{n} \sum_{\substack{i=0 \\ i \neq j}}^n \mathbf{x}^{(i)}$$

súlypontjára. A tükrözött pont koordinátáit az

$$\mathbf{x}_r = 2\mathbf{x}_c - \mathbf{x}^{(j)}$$

képlettel számíthatjuk ki. Ha $f(\mathbf{x}_r)$ nem kisebb, mint az előző lépésbeli legnagyobb függvényérték, $f(\mathbf{x}^{(j)})$, akkor a tükrözést nem fogadjuk el, hanem ahelyett a legjobb csúspontból fele akkorára zsugorítjuk a szimplexet: legyen $\mathbf{x}^{(k)}$ a legjobb csúspontja a szimplexnek, azaz ebben a legkisebb a függvényérték. Ekkor a többi csúspontot az

$$\mathbf{x}^{(i)} \leftarrow \mathbf{x}^{(k)} + \frac{1}{2}(\mathbf{x}^{(i)} - \mathbf{x}^{(k)}), \quad i = 0, 1, \dots, k-1, k+1, \dots, n$$

képlettel számoljuk újra. Ezután a kapott (tükrözött vagy zsugorított) szimplexszel megismételjük az eljárást.

Az előbbi iterációs módszerhez többféle megállási feltételt, illetve feltétel kombinációt adhatunk meg. Például megkövetelhetjük, hogy az eljárás akkor érjen véget, ha a szimplex egy előre megadott méretnél kisebb lesz. A szimplex méretét definiálhatjuk például a leghosszabb éle hosszaként, azaz a $\max\{\|\mathbf{x}^{(i)} - \mathbf{x}^{(j)}\| : i, j = 0, \dots, n\}$ képlettel. Egy másik lehetőség lehet az, hogy a szimplexek súlypontjaiban felvett f_k függvényérték sorozatára alkalmazzuk az $|f_{k+1} - f_k| < \varepsilon$ feltételt. Egy harmadik megállási feltétel lehet a következő: Legyen $\bar{f}$ a csúspontokban felvett függvényértékek átlaga, σ pedig a szórása, azaz

$$\bar{f} = \frac{1}{n+1} \sum_{i=0}^n f(\mathbf{x}^{(i)}), \quad \sigma = \sqrt{\frac{1}{n+1} \sum_{i=0}^n (f(\mathbf{x}^{(i)}) - \bar{f})^2}.$$

Ekkor addig folytatjuk az iterációt, amíg σ kisebb nem lesz mint egy előre megadott tolerancia érték. A függvény minimumhelyét az algoritmus utolsó lépésében kapott szimplex súlypontjával szokás közelíteni.

8.6. példa. Keressük meg az $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvény minimumhelyét! Könnyen látható, hogy a függvénynek az $(1, 0.5)$ pontban van (globális) minimuma. A szimplex módszert alkalmaztuk a feladat megoldására a $(-2, 4)$, $(-1, 4)$ és $(-1.5, 5)$ kezdeti háromszögből kiindulva. Az első 25 lépésben kapott háromszögeket és a csúcspontokhoz tartozó függvényértékeket a 8.2. táblázatban soroltuk fel. A 8.4. ábrán láthatók f szintvonalai és az egyes lépésekben kapott háromszögek. A 25. háromszög középpontja, $(0.9063, 0.3542)$, jó közelítése a pontos minimumhelynek. Az ebben a pontban felvett függvényérték 0.0303, ami közel van a pontos minimum értékhez, 0-hoz. $\square$

8.2. táblázat. Szimplex módszer, $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$


k	$\mathbf{x}^{(k,1)}$	$\mathbf{x}^{(k,2)}$	$\mathbf{x}^{(k,3)}$	$f(\mathbf{x}^{(k,1)})$	$f(\mathbf{x}^{(k,2)})$	$f(\mathbf{x}^{(k,3)})$
0	(-1.000, 4.000)	(-2.000, 4.000)	(-1.500, 5.000)	57.000	34.000	72.563
1	(-2.000, 4.000)	(-1.000, 4.000)	(-1.500, 3.000)	34.000	57.000	26.563
2	(-1.500, 3.000)	(-2.000, 4.000)	(-2.500, 3.000)	26.563	34.000	24.563
3	(-2.500, 3.000)	(-1.500, 3.000)	(-2.000, 2.000)	24.563	26.563	18.000
4	(-2.000, 2.000)	(-2.250, 2.500)	(-1.750, 2.500)	18.000	21.129	18.879
5	(-2.000, 2.000)	(-1.750, 2.500)	(-1.500, 2.000)	18.000	18.879	15.563
6	(-1.500, 2.000)	(-2.000, 2.000)	(-1.750, 1.500)	15.563	18.000	15.129
7	(-1.750, 1.500)	(-1.500, 2.000)	(-1.250, 1.500)	15.129	15.563	12.191
8	(-1.250, 1.500)	(-1.750, 1.500)	(-1.500, 1.000)	12.191	15.129	12.563
9	(-1.250, 1.500)	(-1.500, 1.000)	(-1.000, 1.000)	12.191	12.563	9.000
10	(-1.000, 1.000)	(-1.250, 1.500)	(-0.750, 1.500)	9.000	12.191	12.066
11	(-1.000, 1.000)	(-0.750, 1.500)	(-0.500, 1.000)	9.000	12.066	7.563
12	(-0.500, 1.000)	(-1.000, 1.000)	(-0.750, 0.500)	7.563	9.000	6.316
13	(-0.750, 0.500)	(-0.500, 1.000)	(-0.250, 0.500)	6.316	7.563	4.004
14	(-0.250, 0.500)	(-0.750, 0.500)	(-0.500, 0.000)	4.004	6.316	4.563
15	(-0.250, 0.500)	(-0.500, 0.000)	(0.000, 0.000)	4.004	4.563	2.000
16	(0.000, 0.000)	(-0.250, 0.500)	(0.250, 0.500)	2.000	4.004	2.004
17	(0.000, 0.000)	(0.250, 0.500)	(0.500, 0.000)	2.000	2.004	0.563
18	(0.500, 0.000)	(0.250, 0.000)	(0.375, 0.250)	0.563	1.129	0.910
19	(0.500, 0.000)	(0.375, 0.250)	(0.625, 0.250)	0.563	0.910	0.293
20	(0.625, 0.250)	(0.500, 0.000)	(0.750, 0.000)	0.293	0.563	0.441
21	(0.625, 0.250)	(0.750, 0.000)	(0.875, 0.250)	0.293	0.441	0.102
22	(0.875, 0.250)	(0.750, 0.250)	(0.813, 0.125)	0.102	0.129	0.239
23	(0.875, 0.250)	(0.750, 0.250)	(0.813, 0.375)	0.102	0.129	0.078
24	(0.813, 0.375)	(0.875, 0.250)	(0.938, 0.375)	0.078	0.102	0.024
25	(0.938, 0.375)	(0.875, 0.375)	(0.906, 0.313)	0.024	0.031	0.056

A szimplex módszernek egy módosított változata a *Nelder–Mead-módszer*. Ennél a módszer-nél a szimplexet tükrözzük, illetve megnyújtjuk vagy zsugorítjuk aszerint, hogy milyen értékeket vesz fel a függvény a csúcspontokban. Feltesszük, hogy minden egyes lépésben a csúcspontokat úgy indexezzük, hogy a függvényértékek növekvő sorrendben legyenek, azaz $f(\mathbf{x}^{(0)}) \leq f(\mathbf{x}^{(1)}) \leq \dots \leq f(\mathbf{x}^{(n)})$. Ekkor $\mathbf{x}^{(n)}$ a legrosszabb csúcspont, ezt tükrözzük a szemben fekvő oldal

$$\mathbf{x}_c = \frac{1}{n} \sum_{i=0}^{n-1} \mathbf{x}^{(i)}$$

súlypontjára. Legyen a tükrözött pont $\mathbf{x}_r = 2\mathbf{x}_c - \mathbf{x}^{(n)}$. Vizsgáljuk meg, hogy milyen értéket vesz fel az f függvény $\mathbf{x}_r$ -ben. Három esetet különböztetünk meg: 1. $f(\mathbf{x}^{(0)}) < f(\mathbf{x}_r) < f(\mathbf{x}^{(n-1)})$, 2. $f(\mathbf{x}_r) \leq f(\mathbf{x}^{(0)})$, azaz $\mathbf{x}_r$ lenne az új legjobb pont, és 3. $f(\mathbf{x}_r) \geq f(\mathbf{x}^{(n-1)})$, azaz $\mathbf{x}_r$ lenne az új legrosszabb pont.

Az 1. esetben $\mathbf{x}^{(n)}$ -t $\mathbf{x}_r$ -re kicseréljük (elfogadtuk a tükrözést), és folytatjuk az iterációt.



8.4. ábra. Szimplex módszer.

A 2. esetben először megpróbáljuk az $\mathbf{x}_r$ irányban megnyújtani egy kicsit a szimplexet, hátha még jobb pontot kapunk. Legyen

$$\mathbf{x}_e := \mathbf{x}_c + \alpha(\mathbf{x}_r - \mathbf{x}_c),$$

ahol $\alpha > 1$ egy rögzített szám (egy paraméter a módszerben). Ha ekkor $f(\mathbf{x}_e) < f(\mathbf{x}^{(0)})$ teljesül, akkor a megnyújtást sikeresnek ítéljük, és $\mathbf{x}^{(n)}$ -t $\mathbf{x}_e$ -re cseréljük ki. Ellenkező esetben viszont $\mathbf{x}^{(n)}$ -t $\mathbf{x}_r$ -re cseréljük ki, azaz tükrözzük, de nem nyújtjuk meg a szimplexet.

A 3. esetben azt gondoljuk, hogy túl messze tükröztük $\mathbf{x}^{(n)}$ -t, így megpróbáljuk zsugorítani a szimplexet. Legyen

$$\mathbf{x}_z := \begin{cases} \mathbf{x}_c - \beta(\mathbf{x}_r - \mathbf{x}_c), & \text{ha } f(\mathbf{x}^{(n)}) < f(\mathbf{x}_r), \\ \mathbf{x}_c + \beta(\mathbf{x}_r - \mathbf{x}_c), & \text{ha } f(\mathbf{x}^{(n)}) \geq f(\mathbf{x}_r), \end{cases}$$

ahol $0 < \beta < 1$ egy újabb paraméter. Ha $f(\mathbf{x}_z) < \min\{f(\mathbf{x}^{(n)}), f(\mathbf{x}_r)\}$, akkor $\mathbf{x}^{(n)}$ -t $\mathbf{x}_z$ -vel cseréljük fel. Ellenkező esetben viszont a szimplexet a legjobb pontjából, $\mathbf{x}^{(0)}$ -ból a felére zsugorítjuk össze:

$$\mathbf{x}^{(i)} \leftarrow \mathbf{x}^{(0)} + \frac{1}{2}(\mathbf{x}^{(i)} - \mathbf{x}^{(0)}), \quad i = 1, \dots, n.$$

8.7. példa. A Nelder–Mead-módszert alkalmaztuk az $\alpha = 1.4$ és $\beta = 0.7$ paraméter értékekkel a 8.6. feladatban már vizsgált $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvény minimumhelyének keresésére. Most is a $(-2, 4)$, $(-1, 4)$ és $(-1.5, 5)$ háromszögből indultunk ki. A kapott sorozat első 17 tagja látható a 8.3. táblázatban, illetve a 8.5. ábrán. A 17. háromszög középpontja $(1.0071, 0.5929)$, a hozzá tartozó függvényérték pedig 0.0295. Látható, hogy ez a módszer sokkal gyorsabban konvergál a minimumhelyhez, mint a szimplex módszer. $\square$


Feladatok

1. Keresse meg a következő függvények minimumhelyét Nelder–Mead-módszerrel!

- (a) $f(x, y) = x^2 + 5y^2$, (b) $f(x, y) = x^2 + (x + y - 2)^2$,
 (c) $f(x, y) = 3x^2 + e^{(x-y)^2}$, (d) $f(x, y) = x^2 + \cos^2(x - y)$

8.3. táblázat. Nelder–Mead-módszer, $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$

k	$\mathbf{x}^{(k,1)}$	$\mathbf{x}^{(k,2)}$	$\mathbf{x}^{(k,3)}$	$f(\mathbf{x}^{(k,1)})$	$f(\mathbf{x}^{(k,2)})$	$f(\mathbf{x}^{(k,3)})$
0	(-1.000, 4.000)	(-2.000, 4.000)	(-1.500, 5.000)	57.000	34.000	72.563
1	(-2.000, 4.000)	(-1.000, 4.000)	(-1.500, 2.600)	34.000	57.000	21.203
2	(-1.500, 2.600)	(-2.000, 4.000)	(-2.500, 2.600)	21.203	34.000	25.603
3	(-1.500, 2.600)	(-2.500, 2.600)	(-2.000, 1.200)	21.203	25.603	20.560
4	(-2.000, 1.200)	(-1.500, 2.600)	(-0.700, 0.920)	20.560	21.203	7.602
5	(-0.700, 0.920)	(-2.000, 1.200)	(-1.200, -0.480)	7.602	20.560	15.440
6	(-0.700, 0.920)	(-1.200, -0.480)	(0.520, -1.152)	7.602	15.440	7.088
7	(0.520, -1.152)	(-0.700, 0.920)	(1.464, 0.394)	7.088	7.602	2.270
8	(1.464, 0.394)	(0.520, -1.152)	(-0.192, 0.530)	2.270	7.088	3.891
9	(1.464, 0.394)	(-0.192, 0.530)	(0.555, -0.668)	2.270	3.891	3.097
10	(1.464, 0.394)	(0.555, -0.668)	(0.168, 0.330)	2.270	3.097	1.783
11	(0.168, 0.330)	(1.464, 0.394)	(0.999, 1.083)	1.783	2.270	1.362
12	(0.999, 1.083)	(0.168, 0.330)	(1.200, 0.487)	1.362	1.783	0.296
13	(1.200, 0.487)	(0.999, 1.083)	(0.448, 0.467)	0.296	1.362	1.147
14	(1.200, 0.487)	(0.448, 0.467)	(0.648, -0.129)	0.296	1.147	0.707
15	(1.200, 0.487)	(0.648, -0.129)	(0.591, 0.380)	0.296	0.707	0.505
16	(1.200, 0.487)	(0.591, 0.380)	(1.068, 0.828)	0.296	0.505	0.274
17	(1.068, 0.828)	(1.200, 0.487)	(0.754, 0.464)	0.274	0.296	0.251



8.5. ábra. Nelder–Mead-módszer.

Több különböző α , β paraméter értékekkel próbálja ki a módszert!

- Alkalmazza a Nelder–Mead-módszert tetszőleges $\alpha > 1$ és $0 < \beta < 1$ paraméter értékeket használva az $f(x) = x^2 - y^2$ függvényre és a $[0, 1]$, $[0, -1]$, $[1, 0]$ kezdeti pontokra! Mit tapasztal? Mit tapasztal, ha ugyanerre a függvényre és pontokra a szimplex módszert alkalmazza?
- Fogalmazza meg a szimplex módszert egyváltozós függvények minimumhelyének meghatározására, és alkalmazza a 8.2. szakasz 1. feladatában szereplő függvényekre!
- Tekintsük a következő, deriváltat nem használó módszert kétváltozós függvények minimalizálására: legyen f egy kétváltozós függvény, $(p_1^{(0)}, p_2^{(0)})$ egy adott kezdeti pont. Minimalizáljuk a $t \mapsto f(p_1^{(0)} + t, p_2^{(0)})$ egyváltozós függvényt (például szimplex módszerrel, lásd az előző példát). Legyen t_1 a minimumhely. Ekkor jelölje $(p_1^{(1)}, p_2^{(1)}) := (p_1^{(0)} + t_1, p_2^{(0)})$. Ezután minimalizáljuk a $t \mapsto f(p_1^{(1)}, p_2^{(1)} + t)$ egyváltozós függvényt. A kapott t_2 minimumhelyhez tartozó $(p_1^{(2)}, p_2^{(2)}) = (p_1^{(1)}, p_2^{(1)} + t_2)$ pontból megismételjük az eljárást. Így felváltva az x - illetve y -tengely irányában egydimenziós minimumkeresési feladatokat megoldva kapjuk a sorozat következő pontját. Alkalmazza ezt a módszert az 1.

feladatban felsorolt függvényekre! Hasonlítsa össze a kapott sorozat konvergenciájának gyorsaságát a Nelder–Mead-módszer gyorsaságával!

8.4. Gradiens módszer

Tekintsünk egy $f: \mathbb{R}^n \rightarrow \mathbb{R}$ függvényt. Analízisből ismert tétel szerint egy $\mathbf{p}$ pontban az f függvény a $-f'(\mathbf{p})$ irányban csökken a leggyorsabban:

8.8. tétel. Legyen $f \in C^1$. Ekkor a

$$\lim_{t \rightarrow 0+} \frac{f(\mathbf{p} + t\mathbf{u}) - f(\mathbf{p})}{t}, \quad \|\mathbf{u}\|_2 = 1$$

iránymenti deriváltak minimuma az $\mathbf{u} = -f'(\mathbf{p})/\|f'(\mathbf{p})\|_2$ irányban van.

Egy $\mathbf{u}$ irányt az f függvény $\mathbf{p}$ pontbeli *lejtőjének* nevezzük, ha létezik olyan $\delta > 0$, hogy $f(\mathbf{p} + t\mathbf{u}) < f(\mathbf{p})$ minden $0 < t < \delta$ -ra, azaz a függvény csökken a $\mathbf{p}$ pontból az $\mathbf{u}$ irány mentén indulva. A 8.8. tételt úgy is megfogalmazhatjuk, hogy az f függvénynek a $\mathbf{p}$ pontban a $-f'(\mathbf{p})$ irányban legmeredekebb a lejtője.

A *gradiens módszer* szerint egy $\mathbf{p}^{(0)}$ kezdeti pontból a negatív gradiensvektor irányában kell elmozdulni. Szokás az előbbieket miatt ezt a *legmeredekebb lejtő módszerének* is nevezni. A módszer általános képlete ezért:

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \alpha_k f'(\mathbf{p}^{(k)}), \quad (8.5)$$

ahol α_k a lépésközt meghatározó szorzótényező. A (8.5) gradiens módszernek több változata van. A legegyszerűbb esetben a lépésköz állandó. Legyen h rögzített, és használjuk az $\alpha_k = h/\|f'(\mathbf{p}^{(k)})\|_2$ számot. Ekkor az egyes pontok közötti távolság konstans h lesz. Természetesen ekkor általában nem várható el, hogy h -nál pontosabban megközelítsük a minimumhelyet.

Egy másik változatban úgy választjuk meg a lépésközt, hogy

$$\phi_k(\alpha_k) = \min_{t \in \mathbb{R}} \phi_k(t)$$

legyen, ahol

$$\phi_k(t) := f(\mathbf{p}^{(k)} - t f'(\mathbf{p}^{(k)})). \quad (8.6)$$

Ekkor minden egyes lépésben a gradiensvektor által meghatározott egyenes mentén egy egyváltozós függvényt kell minimalizálni. Ez utóbbi módon választott lépésközt használó gradiens módszert *optimális gradiens módszernek* hívjuk.


Az optimális gradiens módszernél a gradiensvektorral párhuzamos egyenes mentén egy olyan pontig lépünk, ahol az egyenes érint egy szintvonalat. Abból a pontból pedig a pontbeli gradiensvektorral párhuzamosan lépünk tovább. Ebből következik, hogy az optimális gradiens módszernél az egymás utáni lépések irányai merőlegesek egymásra. (Lásd a 3. feladatot!)

Megmutatható, hogy az optimális gradiens módszer lokálisan lineárisan konvergens. A sorozat aszimptotikus hibakonstansa néha közel van 1-hez, azaz a konvergencia lassú is lehet.


8.9. példa. Tekintsük újra a 8.6. és 8.7. példákban vizsgált $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényt. Először az $\alpha_k = 0.3/\|f'(\mathbf{p}^{(k)})\|_2$ lépésközzel futtadjuk a gradiens módszert, két kezdeti pontból indítva a módszert: a $(-1, 4)$ kezdeti értékből (piros karikák) és a $(0.5, 3.5)$ kezdeti értékből (zöld karikák). A kapott sorozatok első 25 tagja a 8.6. ábrán látható. A sorozatok lassan közelítik meg az $(1, 0.5)$

minimumhelyet (kék pont), és annak közelében oszcillálnak. Vegyük észre, hogy ahogy az az analízisből ismert, a gradiensvektor merőleges a ponthoz tartozó szintvonalra, így a gradiens módszer sorozata mindig a szintvonalra merőleges irányban mozdul el.

Ezután az optimális gradiens módszert alkalmaztuk a $(-1, 4)$ és az $(0.5, 3.5)$ kezdőpontból indulva. A két sorozat első 3 illetve 12 tagját a 8.7. ábrán láthatjuk. Az első sorozat gyorsan a minimumhely közelébe került. A második is gyorsan a minimumhelyet tartalmazó hosszúkás „völgybe” került, de ezután ott csak lassan, cikcakkban haladt a minimumhely felé. $\square$



8.6. ábra. Gradiens módszer konstans lépésközt használva.



8.7. ábra. Optimális gradiens módszer.

Ha f gradiensvektorát nem tudjuk vagy nem akarjuk kiszámolni (túl sok műveletet igényel), használhatjuk (8.5) következő változatát:

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \alpha_k \mathbf{v}^{(k)}, \quad (8.7)$$

ahol a $\mathbf{v}^{(k)}$ vektor i -edik komponensét a

$$v_i^{(k)} = \frac{1}{h} \left(f(\mathbf{p}^{(k)} + h\mathbf{e}^{(i)}) - f(\mathbf{p}^{(k)}) \right), \quad i = 1, \dots, n$$

képlettel számoljuk ($\mathbf{e}^{(i)}$ az i -edik egységvektor).

Feladatok

1. Alkalmazza a gradiens módszert a 8.3. szakasz 1. feladatában felsorolt függvényekre! Válasszon tetszőleges kezdőpontot, és használja az $\alpha_k = h/\|f'(\mathbf{p}^{(k)})\|_2$ lépésközt valamely $h > 0$ -ra, illetve az optimális gradiens módszert!
2. Ismételje meg az előző feladatot az $\alpha_k = h$ lépésközt használva!
3. Számítsa ki a (8.6) képlettel definiált ϕ_k függvény deriváltját! A derivált $t = \alpha_k$ pontbeli értékéből vezesse le, hogy a $\mathbf{p}^{(k+2)} - \mathbf{p}^{(k+1)}$ és $\mathbf{p}^{(k+1)} - \mathbf{p}^{(k)}$ vektorok merőlegesek egymásra! Magyarázza meg, hogy a numerikus módszerrel generált 8.7. ábrán a jobb oldali sorozat első és második lépése miért nem merőleges egymásra!

8.5. Lineáris egyenletrendszerek megoldása gradiens módszerrel

Legyen $\mathbf{A} \in \mathbb{R}^{n \times n}$ szimmetrikus mátrix, $\mathbf{b} \in \mathbb{R}^n$, $c \in \mathbb{R}$, és tekintsük a

$$g: \mathbb{R}^n \rightarrow \mathbb{R}, \quad g(\mathbf{x}) := \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} + c \quad (8.8)$$

alakú kvadratikus függvényt. Az $\mathbf{A} = (a_{ij})$, $\mathbf{x} = (x_1, \dots, x_n)^T$, $\mathbf{b} = (b_1, \dots, b_n)^T$ jelöléseket használva felírhatjuk g -t a következő alakban:

$$g(x_1, \dots, x_n) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i + c.$$

Számítsuk ki a $\frac{\partial g}{\partial x_i}$ parciális deriváltat. A feltevés szerint $a_{ij} = a_{ji}$, ezért

$$\frac{\partial g}{\partial x_i}(x_1, \dots, x_n) = \frac{1}{2} \sum_{j=1}^n (a_{ij} x_j + a_{ji} x_j) - b_i = \sum_{j=1}^n a_{ij} x_j - b_i,$$

azaz vektoriális alakban

$$g'(\mathbf{x}) = \left(\frac{\partial g}{\partial x_1}(\mathbf{x}), \dots, \frac{\partial g}{\partial x_n}(\mathbf{x}) \right)^T = \mathbf{A} \mathbf{x} - \mathbf{b}. \quad (8.9)$$

Így ha $\mathbf{A}$ invertálható, akkor g -nek pontosan egy kritikus pontja van, amely az $\mathbf{A} \mathbf{x} = \mathbf{b}$ egyenlet megoldása. Legyen $\bar{\mathbf{x}}$ a g függvény kritikus pontja és $\mathbf{x} = \bar{\mathbf{x}} + \Delta \mathbf{x}$.

$$\begin{aligned} g(\bar{\mathbf{x}} + \Delta \mathbf{x}) &= \frac{1}{2} (\bar{\mathbf{x}} + \Delta \mathbf{x})^T \mathbf{A} (\bar{\mathbf{x}} + \Delta \mathbf{x}) - \mathbf{b}^T (\bar{\mathbf{x}} + \Delta \mathbf{x}) + c \\ &= \frac{1}{2} \bar{\mathbf{x}}^T \mathbf{A} \bar{\mathbf{x}} + \frac{1}{2} \bar{\mathbf{x}}^T \mathbf{A} \Delta \mathbf{x} + \frac{1}{2} (\Delta \mathbf{x})^T \mathbf{A} \bar{\mathbf{x}} + \frac{1}{2} (\Delta \mathbf{x})^T \mathbf{A} \Delta \mathbf{x} \\ &\quad - \mathbf{b}^T \bar{\mathbf{x}} - \mathbf{b}^T \Delta \mathbf{x} + c. \end{aligned}$$

Ebből kapjuk az $\mathbf{A} = \mathbf{A}^T$, $\bar{\mathbf{x}}^T \mathbf{A} \Delta \mathbf{x} = (\Delta \mathbf{x})^T \mathbf{A} \bar{\mathbf{x}}$, $\mathbf{b}^T \Delta \mathbf{x} = (\Delta \mathbf{x})^T \mathbf{b}$ és az $\mathbf{A} \bar{\mathbf{x}} = \mathbf{b}$ összefüggéseket felhasználva, hogy

$$\begin{aligned} g(\bar{\mathbf{x}} + \Delta \mathbf{x}) &= \frac{1}{2} \bar{\mathbf{x}}^T \mathbf{A} \bar{\mathbf{x}} - \mathbf{b}^T \bar{\mathbf{x}} + (\Delta \mathbf{x})^T (\mathbf{A} \bar{\mathbf{x}} - \mathbf{b}) + \frac{1}{2} (\Delta \mathbf{x})^T \mathbf{A} \Delta \mathbf{x} + c \\ &= g(\bar{\mathbf{x}}) + \frac{1}{2} (\Delta \mathbf{x})^T \mathbf{A} \Delta \mathbf{x}. \end{aligned}$$

Ezért

$$g(\bar{\mathbf{x}} + \Delta \mathbf{x}) - g(\bar{\mathbf{x}}) = \frac{1}{2} (\Delta \mathbf{x})^T \mathbf{A} \Delta \mathbf{x}. \quad (8.10)$$

Ha $\mathbf{A}$ pozitív definit mátrix, akkor $g(\bar{\mathbf{x}} + \Delta \mathbf{x}) - g(\bar{\mathbf{x}}) > 0$ minden $\Delta \mathbf{x} \neq \mathbf{0}$ vektorra, azaz $\bar{\mathbf{x}}$ minimalizálja a g függvényt. Ehhez hasonlóan, ha $\mathbf{A}$ negatív definit, akkor a (8.10) egyenletből következik, hogy g -nek maximuma van $\bar{\mathbf{x}}$ -ben. Pozitív ill. negatív definit mátrixok a 3.9. tétel szerint invertálhatók. Ezzel beláttuk tehát a következő tételt:

8.10. tétel. *Legyen $\mathbf{A}$ szimmetrikus. Ekkor a $g(\mathbf{x}) := \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} + c$ kvadratikus függvény gradiensvektora $g'(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$. Ha $\mathbf{A}$ pozitív (negatív) definit, akkor g -nek létezik globális minimuma (maximuma), amelyet a függvény az $\mathbf{x} = \mathbf{A}^{-1} \mathbf{b}$ pontban vesz fel.*

Az előző tétel bizonyításából könnyen belátható:

8.11. következmény. Ha egy kvadratikus függvénynek egy pontban lokális minimuma (maximuma) van, akkor ott a függvénynek globális minimuma (maximuma) is van.

Ha $\mathbf{A}$ egy szimmetrikus pozitív definit mátrix, akkor a 8.10. tétel szerint az $\mathbf{Ax} = \mathbf{b}$ lineáris egyenletrendszert megoldhatjuk úgy, hogy definiáljuk a g kvadratikus függvényt a (8.8) képlettel, és optimális gradiens módszerrel minimalizáljuk azt. Definiáljuk tehát a

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \alpha_k \mathbf{v}^{(k)}$$

sorozatot, ahol

$$\mathbf{v}^{(k)} = g'(\mathbf{p}^{(k)}) = \mathbf{Ap}^{(k)} - \mathbf{b}.$$

α_k -t az optimális gradiens módszer definíciójának megfelelően a $\phi_k(t) = g(\mathbf{p}^{(k)} - t\mathbf{v}^{(k)})$ egyváltozós függvény minimumhelyének választjuk. Az ϕ_k függvény egy másodfokú polinom, hiszen

$$\begin{aligned} \phi_k(t) &= \frac{1}{2} (\mathbf{p}^{(k)} - t\mathbf{v}^{(k)})^T \mathbf{A} (\mathbf{p}^{(k)} - t\mathbf{v}^{(k)}) - \mathbf{b}^T (\mathbf{p}^{(k)} - t\mathbf{v}^{(k)}) + c \\ &= t^2 \frac{1}{2} (\mathbf{v}^{(k)})^T \mathbf{A} \mathbf{v}^{(k)} - t (\mathbf{v}^{(k)})^T (\mathbf{Ap}^{(k)} - \mathbf{b}) + \frac{1}{2} (\mathbf{p}^{(k)})^T \mathbf{A} \mathbf{p}^{(k)} - \mathbf{b}^T \mathbf{p}^{(k)} + c. \end{aligned}$$

Ezért ϕ_k minimumhelyét explicit módon meg tudjuk adni:

$$\alpha_k = \frac{(\mathbf{v}^{(k)})^T (\mathbf{Ap}^{(k)} - \mathbf{b})}{(\mathbf{v}^{(k)})^T \mathbf{A} \mathbf{v}^{(k)}}.$$

Ha bevezetjük az $\mathbf{r}^{(k)} := \mathbf{b} - \mathbf{Ap}^{(k)}$ reziduális vektort, akkor az előbbi képleteket összefoglalhatjuk a következő alakban:

$$\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{Ap}^{(k)} \quad (8.11)$$

$$\alpha_k = \frac{(\mathbf{r}^{(k)})^T \mathbf{r}^{(k)}}{(\mathbf{r}^{(k)})^T \mathbf{A} \mathbf{r}^{(k)}} \quad (8.12)$$

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} + \alpha_k \mathbf{r}^{(k)}. \quad (8.13)$$

8.12. példa. A

$$\begin{array}{rrrrr} 4x_1 & + & 2x_2 & - & x_3 & = & 0 \\ 2x_1 & + & 5x_2 & & & = & 8 \\ -x_1 & & & + & 3x_3 & = & 1. \end{array}$$

lineáris egyenletrendszerre alkalmaztuk a gradiens módszert a (8.11)-(8.13) rekurzív képletekkel a $\mathbf{p}^{(0)} = (3, 3, 3)^T$ kezdőértékből kiindulva. Megjegyezzük, hogy a módszer alkalmazható, hiszen a lineáris rendszer együtthatómátrixa szimmetrikus és pozitív definit. A kapott $\mathbf{p}^{(k)}$ sorozat első 13 tagját a 8.4. táblázatban soroltuk fel a közelítés hibájával együtt. Megjegyezzük, hogy a pontos megoldás $(-1, 2, 0)$. $\square$

Feladatok

1. Mutassa meg, hogy tetszőleges

$$g(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n \tilde{a}_{ij} x_i x_j + \sum_{i=1}^n \tilde{b}_i x_i + c$$

kvadratikus függvény felírható (8.8) alakban! Hogy írhatjuk fel $g'(\mathbf{x})$ -et és $g''(\mathbf{x})$ -et mátrix jelölést használva?

8.4. táblázat. Lineáris egyenletrendszer megoldása gradiens módszerrel

k	$\mathbf{p}^{(k)}$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$
0	(3.00000000, 3.00000000, 3.00000000)	5.09901951
1	(0.43469388, 0.77673469, 2.14489796)	2.85575065
2	(0.03799038, 1.89938726, 0.41611180)	1.12280719
3	(-0.59954375, 1.61568290, 0.37817223)	0.67162421
4	(-0.75093609, 1.98854968, 0.13393796)	0.28302529
5	(-0.90321440, 1.90857051, 0.10622765)	0.17032651
6	(-0.93575911, 1.99605148, 0.03257991)	0.07213829
7	(-0.97504377, 1.97631917, 0.02650106)	0.04342696
8	(-0.98365956, 1.99904876, 0.00839916)	0.01839730
9	(-0.99365117, 1.99398134, 0.00679190)	0.01107528
10	(-0.99583018, 1.99975420, 0.00213698)	0.00469196
11	(-0.99837993, 1.99846385, 0.00173029)	0.00282459
12	(-0.99893668, 1.99993749, 0.00054530)	0.00119662
13	(-0.99958687, 1.99960829, 0.00044139)	0.00072037

- Igazolja a 8.11. következményt!
- Ellenőrizze a (8.11)-(8.13) képletek levezetését!
- Alkalmazza a gradiens módszert a következő kvadratikusan függvények minimumhelyének meghatározására:

$$(a) \quad f(x, y) = 2x^2 - 12x + 3y^2 + 30y, \quad (b) \quad f(x, y) = 2x^2 - 4xy + 3y^2 - 2y$$

- Oldja meg a következő lineáris egyenletrendszereket gradiens módszerrel:

$$(a) \quad \begin{aligned} 4x_1 - 3x_2 &= 4 \\ -3x_1 + 3x_2 &= 3 \end{aligned} \quad (b) \quad \begin{aligned} 6x_1 + 3x_2 - 2x_3 &= 6 \\ 3x_1 + 5x_2 - x_3 &= -4 \\ -2x_1 - x_2 + 3x_3 &= -2 \end{aligned}$$

- Legyen $f(x, y) = \frac{1}{2}x^2 + \frac{9}{2}y^2$. Igazolja, hogy a gradiens módszert alkalmazva a $\mathbf{p}^{(0)} = (9, 1)^T$ pontból indulva a

$$\mathbf{p}^{(k)} = \begin{pmatrix} 9 \\ (-1)^k \end{pmatrix} 0.8^k$$

pontokat kapjuk! Mi a sorozat aszimptotikus hibakonstansa? Adjon meg egy olyan függvényt, ahol a gradiens módszer sorozatának aszimptotikus hibakonstansa egy előre megadott $0 < \alpha < 1$ szám!

8.6. Newton-módszer

Most tekintsünk egy $f: \mathbb{R}^n \rightarrow \mathbb{R}$ függvényt. Rögzítsünk egy $\mathbf{p}^{(0)}$ vektort. Ha $f \in C^3$, akkor $\mathbf{p}^{(0)}$ egy környezetében f közelíthető a

$$g(\mathbf{x}) := f(\mathbf{p}^{(0)}) + f'(\mathbf{p}^{(0)})^T(\mathbf{x} - \mathbf{p}^{(0)}) + \frac{1}{2}(\mathbf{x} - \mathbf{p}^{(0)})^T f''(\mathbf{p}^{(0)})(\mathbf{x} - \mathbf{p}^{(0)}) \quad (8.14)$$

másodfokú Taylor-polinomjával, ahol $f'(\mathbf{p}^{(0)})$ f gradiensvektora, $f''(\mathbf{p}^{(0)})$ pedig f Hesse-mátrixa $\mathbf{p}^{(0)}$ -ban. Tegyük fel, hogy $f''(\mathbf{p}^{(0)})$ pozitív definit. Ekkor a 8.10. tétel szerint g -nek globális minimuma létezik, amelyet a

$$\mathbf{p}^{(1)} = \mathbf{p}^{(0)} - \left(f''(\mathbf{p}^{(0)})\right)^{-1} f'(\mathbf{p}^{(0)})$$

pontban vesz fel. Ekkor $\mathbf{p}^{(1)}$ -et tekinthetjük f minimumhelye közelítésének. Ezután megismételjük az eljárást a $\mathbf{p}^{(1)}$ pontbeli Taylor-közelítést használva. Így definiálhatjuk a következő iterációs módszert:

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \left(f''(\mathbf{p}^{(k)})\right)^{-1} f'(\mathbf{p}^{(k)}) \quad (8.15)$$

A (8.15) iterációs módszert *Newton-féle minimumkeresési módszernek* hívjuk. Könnyen látható, hogy ez azonos az $f'(\mathbf{x}) = \mathbf{0}$ egyenletrendszer megoldására felírt Newton-iterációval. Ebből kapjuk rögtön a következő tételt.

8.13. tétel. Legyen $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^3$, $f'(\mathbf{p}) = \mathbf{0}$ és $\mathbf{f}''(\mathbf{p})$ pozitív definit. Ekkor f -nek $\mathbf{p}$ -ben lokális minimuma van, és a (8.15) Newton-iteráció lokálisan kvadratikusan konvergál $\mathbf{p}$ -hez.

Bizonyítás. A 8.1. tételt alkalmazva kapjuk, hogy $\mathbf{p}$ -ben f -nek lokális minimuma van. Mivel a (8.15) iteráció ekvivalens az $f'(\mathbf{x}) = \mathbf{0}$ egyenlet $\mathbf{p}$ gyökének keresésére felírt Newton-módszerrel, ezért a 2.56. tételből kapjuk, hogy a (8.15) iteráció lokálisan kvadratikusan konvergál $\mathbf{p}$ -hez. $\square$

8.14. példa. Alkalmazzuk a Newton-módszert a 8.6., 8.7. és 8.9. példákban vizsgált $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényre. A $(-1, 4)^T$ pontból indított (8.15) iteráció első 5 tagját a 8.5. táblázatban tüntettük fel. A sorozat igen gyorsan megközelítette a pontos $(1, 0.5)^T$ minimumhelyet. Megjegyezzük, hogy az $(1, 3)^T$ pontból indított Newton-sorozat egy lépésben már a pontos minimumhelyet adja vissza. $\square$

8.5. táblázat. Newton-módszer, $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2^2}$
0	(-1.00000000, 4.00000000)	57.00000000	4.03112887	
1	(-1.33333333, 0.83333333)	10.90123457	2.35702260	0.14504754
2	(0.76666667, -1.91111111)	19.55698889	2.42237512	0.43602752
3	(0.80979667, 0.32695523)	0.07235807	0.25714159	0.04382173
4	(0.99964684, 0.48162536)	0.00129935	0.01837803	0.27794212
5	(0.99998771, 0.49998766)	0.00000000	0.00001742	0.05156519

8.15. példa. Tekintsük az $f(x, y) = 0.1(x^2 - 2y)^4 + (x - 1)^2$ függvényt. Könnyű látni, hogy ennek a függvénynek is $(1, 0.5)^T$ a minimumhelye. Ellenőrizhető, hogy a minimumpontban a függvény Hesse mátrixa $\mathbf{f}''(1, 0.5) = \mathbf{0}$, ami nem pozitív definit. Ennek ellenére a Newton-módszer a $(-1, 4)^T$ kezdőértékből indítva konvergens lesz (lásd a 8.6. táblázatot), csak a konvergencia sebessége lineáris lesz. $\square$

Feladatok

1. Alkalmazza a Newton-féle minimumkeresési módszert a 8.3. szakasz 1. feladatában felsorolt függvényekre!
2. Mutassa meg, hogy olyan kvadratikusságú függvényekre, melyeknek Hesse-mátrixa pozitív definit, a Newton-módszer egy lépésben a pontos minimumhelyet adja vissza!
3. Igazolja, hogy ha a 8.13. tétel feltételei teljesülnek, és ha $\mathbf{p}^{(0)}$ elegendően közel van $\mathbf{p}$ -hez, akkor a (8.15) sorozat minden k -ra definiálható, azaz $\mathbf{f}''(\mathbf{p}^{(k)})$ invertálható!

8.6. táblázat. Newton-módszer, $f(x, y) = 0.1(x^2 - 2y)^4 + (x - 1)^2$

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2}$
0	(-1.00000000, 4.00000000)	244.10000000	4.03112887	
1	(-1.01468429, 2.84801762)	51.47734819	3.09388745	0.76749902
2	(-1.06550085, 2.12183854)	13.60182932	2.62614813	0.84881825
3	(-1.25304590, 1.80360379)	6.79822461	2.60299802	0.99118476
4	(-2.19917836, 2.64963726)	10.23933318	3.85430701	1.48071838
5	(1.13216300, -4.75372475)	1355.09401353	5.25538684	1.36351018
6	(1.13190045, -2.95581491)	267.68684927	3.45833116	0.65805454
7	(1.13102026, -1.75800646)	52.89017856	2.26180447	0.65401616
8	(1.12811546, -0.96208855)	10.46057564	1.46769088	0.64890263
9	(1.11900871, -0.43955842)	2.07752857	0.94706552	0.64527588
10	(1.09458417, -0.11167347)	0.41720946	0.61894313	0.65353781
11	(1.05056809, 0.07705747)	0.08386326	0.42595483	0.68819704
12	(1.01290080, 0.19574848)	0.01637137	0.30452490	0.71492300
13	(1.00119582, 0.28963767)	0.00320655	0.21036572	0.69079974
14	(1.00003517, 0.35899525)	0.00063312	0.14100475	0.67028386
15	(1.00000031, 0.40597370)	0.00012506	0.09402630	0.66683071
16	(1.00000000, 0.43731559)	0.00002470	0.06268441	0.66666888
17	(1.00000000, 0.45821040)	0.00000488	0.04178960	0.66666668
18	(1.00000000, 0.47214026)	0.00000096	0.02785974	0.66666667
19	(1.00000000, 0.48142684)	0.00000019	0.01857316	0.66666667
20	(1.00000000, 0.48761789)	0.00000004	0.01238211	0.66666667

8.7. Kvázi-Newton módszerek

Az előző szakaszhoz hasonlóan közelítsük az f függvényt egy $\mathbf{p}^{(k)}$ pontja környezetében a

$$g(\mathbf{x}) := f(\mathbf{p}^{(k)}) + \left(\mathbf{v}^{(k)}\right)^T (\mathbf{x} - \mathbf{p}^{(k)}) + \frac{1}{2}(\mathbf{x} - \mathbf{p}^{(k)})^T \mathbf{A}^{(k)}(\mathbf{x} - \mathbf{p}^{(k)}) \quad (8.16)$$

kvadrátikus függvénnyel. Ha $\mathbf{v}^{(k)} \approx f'(\mathbf{p}^{(k)})$ és $\mathbf{A}^{(k)} \approx f''(\mathbf{p}^{(k)})$, akkor (8.16) közelíti f másodfokú $\mathbf{p}^{(k)}$ -körüli Taylor-polinomját, így valóban f közelítésének tekinthető $\mathbf{p}^{(k)}$ egy kis környezetében. Azt várjuk, hogy g minimumhelye közelíteni fogja f minimumhelyét. Ha $\mathbf{A}^{(k)}$ pozitív definit, akkor a 8.10. tétel szerint g minimumhelye a

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \left(\mathbf{A}^{(k)}\right)^{-1} \mathbf{v}^{(k)}. \quad (8.17)$$

pontban van. Ezeket az iterációs eljárásokat *kvázi-Newton minimumkeresési módszereknek* hívjuk.

Választhatjuk $\mathbf{A}^{(k)}$ -t és $\mathbf{v}^{(k)}$ -t az $f''(\mathbf{p}^{(k)})$ Hesse-mátrix és az $f'(\mathbf{p}^{(k)})$ gradiensvektor numerikus közelítésének: $\mathbf{A}^{(k)} = (a_{ij}^{(k)})$ és $\mathbf{v}^{(k)} = (v_1^{(k)}, \dots, v_n^{(k)})^T$, ahol

$$a_{ij}^{(k)} = \frac{1}{h^2} \left(f(\mathbf{p}^{(k)} + h\mathbf{e}^{(i)} + h\mathbf{e}^{(j)}) - f(\mathbf{p}^{(k)} + h\mathbf{e}^{(i)}) - f(\mathbf{p}^{(k)} + h\mathbf{e}^{(j)}) + f(\mathbf{p}^{(k)}) \right) \quad (8.18)$$

és

$$v_i^{(k)} = \frac{1}{h} \left(f(\mathbf{p}^{(k)} + h\mathbf{e}^{(i)}) - f(\mathbf{p}^{(k)}) \right),$$

$i, j = 1, \dots, n$ ($\mathbf{e}^{(i)}$ az i -edik egységvektor, $h > 0$ rögzített kis lépésköz). Itt elsőrendű jobb oldali differencia képlettel közelítettük f elsőrendű parciális deriváltjait, illetve a (7.18)–(7.19) képletekkel a másodrendű parciális deriváltakat. Ezzel a módosítással nincs szükség a pontos Jacobi- és Hesse-mátrix ismeretére, viszont minden iterációs lépésben n^2 nagyságrendű függvény kiértékelést kell elvégezni, arról nem is beszélve, hogy nem tudjuk, mi a h lépésköz ideális választása.

Most tekintsük azt az esetet, amikor a (8.17) képletben $\mathbf{v}^{(k)} = f'(\mathbf{p}^{(k)})$, azaz vizsgáljuk a

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \left(\mathbf{A}^{(k)}\right)^{-1} f'(\mathbf{p}^{(k)}) \quad (8.19)$$

alakú kvázi-Newton módszereket. Feltesszük tehát, hogy a függvény gradiensvektorát ki tudjuk számítani, és a kérdés az, hogyan közelítsük a függvény Hesse-mátrixát. Erre egy lehetőség a 2.13. szakaszban vizsgált Broyden-módszer alkalmazása az $f'(\mathbf{x}) = \mathbf{0}$ egyenletrendszer gyökének meghatározására:

$$\mathbf{A}^{(k)} \mathbf{s}^{(k)} = -f'(\mathbf{p}^{(k)}), \quad (8.20)$$

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} + \mathbf{s}^{(k)}, \quad (8.21)$$

$$\mathbf{y}^{(k)} = f'(\mathbf{p}^{(k+1)}) - f'(\mathbf{p}^{(k)}), \quad (8.22)$$

$$\mathbf{A}^{(k+1)} = \mathbf{A}^{(k)} + \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)} \mathbf{s}^{(k)})(\mathbf{s}^{(k)})^T}{\|\mathbf{s}^{(k)}\|_2^2}. \quad (8.23)$$

8.16. példa. Alkalmazzuk a (8.20)–(8.23) képletekkel definiált Broyden-módszert az $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényre. A $(2, 2)^T$ pontból indítottuk a sorozatot, az $\mathbf{A}^{(0)}$ mátrix pedig az $f''(2, 2)$ Hesse-mátrix $h = 0.05$ lépésközű (8.18) másodrendű differencia képlettel számított közelítése volt. A kapott sorozat első 10 tagját a 8.7. táblázatban láthatjuk. $\square$

8.7. táblázat. Broyden-módszer, $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2}$
0	(2.00000000, 2.00000000)	2.00000e+00	1.80277564	
1	(1.28952043, 0.56127886)	4.59574e-01	0.29593441	0.16415488
2	(1.35039835, 0.89916410)	2.46195e-01	0.53114121	1.79479368
3	(1.24875073, 0.73204681)	1.32833e-01	0.34018032	0.64047058
4	(1.12570322, 0.59780553)	3.67287e-02	0.15927091	0.46819553
5	(1.05911935, 0.54518730)	7.97359e-03	0.07441095	0.46719737
6	(0.99939685, 0.49649610)	3.43894e-05	0.00355544	0.04778109
7	(1.01133354, 0.50962433)	2.69479e-04	0.01486866	4.18194987
8	(1.00464762, 0.50384065)	4.58758e-05	0.00602918	0.40549562
9	(1.00047293, 0.50036811)	4.91375e-07	0.00059931	0.09940111
10	(1.00008014, 0.50006497)	1.37638e-08	0.00010316	0.17213595

A (8.23) iterációs módszerrel az a probléma, hogy mivel $\mathbf{A}^{(k)}$ az $f''(\mathbf{p})$ Hesse-mátrix közelítése, így természetes megkövetelni, hogy $\mathbf{A}^{(k)}$ pozitív definit legyen minden k -ra. Ez ahhoz is kell, hogy a (8.16) kvadratikus függvénynek legyen minimuma minden k -ra. A numerikus tapasztalat is azt támasztja alá, hogy azok a (8.19) alakú kvázi-Newton módszerek a leghatékonyabbak, ahol $\mathbf{A}^{(k)}$ pozitív definit közelítése a Hesse-mátrixnak. A Broyden-módszerrel generált $\mathbf{A}^{(k)}$ mátrixsorozat viszont pozitív definit mátrixból kiindulva még csak nem is szimmetrikus mátrixokat generál.

Az 5.6. tétel szerint ha egy $\mathbf{A}$ mátrix pozitív definit, akkor az $\mathbf{A} = \mathbf{L}\mathbf{L}^T$ Cholesky-felbontása létezik, ahol $\mathbf{L}$ nonszinguláris. Fordítva, ha $\mathbf{A} = \mathbf{M}\mathbf{M}^T$ alakú, ahol $\mathbf{M}$ nonszinguláris, akkor $\mathbf{A}$ pozitív definit, hiszen $\mathbf{x}^T \mathbf{M}\mathbf{M}^T \mathbf{x} = \|\mathbf{M}^T \mathbf{x}\|_2^2 \geq 0$, és egyenlőség csak akkor van, ha $\mathbf{M}^T \mathbf{x} = \mathbf{0}$, és ezért $\mathbf{x} = \mathbf{0}$.

Legyen $\mathbf{A}^{(k)} = \mathbf{M}^{(k)}(\mathbf{M}^{(k)})^T$ alakú, ahol $\mathbf{M}^{(k)}$ invertálható (de nem feltétlenül alulról trian-guláris). A következő Hesse-mátrix közelítést, $\mathbf{A}^{(k+1)}$ -et $\mathbf{A}^{(k+1)} = \mathbf{M}^{(k+1)}(\mathbf{M}^{(k+1)})^T$ alakban keressük, ahol $\mathbf{A}^{(k+1)}$ -től megköveteljük, hogy teljesítse az $\mathbf{A}^{(k+1)} \mathbf{s}^{(k)} = \mathbf{y}^{(k)}$ szelő egyenleteket. A szelő egyenletből következik, hogy $(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)} = (\mathbf{s}^{(k)})^T \mathbf{A}^{(k+1)} \mathbf{s}^{(k)}$, ezért ha $\mathbf{A}^{(k+1)}$ pozitív definit, akkor az

$$(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)} > 0 \quad (8.24)$$

egyenlőtlenség teljesül. Megmutatjuk, hogy (8.24) teljesülése esetén a szelő egyenletnek van pozitív definit megoldása.

Vezessük be a $\mathbf{v}^{(k)} := (\mathbf{M}^{(k+1)})^T \mathbf{s}^{(k)}$ jelölést. Ekkor a szelő egyenlet felírható a következőképpen:

$$(\mathbf{M}^{(k+1)})^T \mathbf{s}^{(k)} = \mathbf{v}^{(k)}, \quad (8.25)$$

$$\mathbf{M}^{(k+1)} \mathbf{v}^{(k)} = \mathbf{y}^{(k)}. \quad (8.26)$$

Az $\mathbf{M}^{(k+1)}$ mátrixot az $\mathbf{M}^{(k)}$ mátrixot módosítva szeretnénk előállítani, ezért a Broyden-módszer levezetését követve (8.26) alapján természetes $\mathbf{M}^{(k+1)}$ -et az

$$\mathbf{M}^{(k+1)} = \mathbf{M}^{(k)} + \frac{(\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})(\mathbf{v}^{(k)})^T}{\|\mathbf{v}^{(k)}\|_2^2} \quad (8.27)$$

alakban keresni. Ekkor $\mathbf{M}^{(k+1)}$ teljesíti a (8.26) egyenletet, és a legkevésbé tér el $\mathbf{M}^{(k)}$ -től abban az értelemben, hogy minden $\mathbf{z} \perp \mathbf{v}^{(k)}$ -ra $\mathbf{M}^{(k+1)} \mathbf{z} = \mathbf{M}^{(k)} \mathbf{z}$. $\mathbf{M}^{(k+1)}$ -et visszahelyettesítve a (8.25) egyenletbe kapjuk, hogy

$$\begin{aligned} \mathbf{v}^{(k)} &= (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} + \frac{((\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})(\mathbf{v}^{(k)})^T)^T}{\|\mathbf{v}^{(k)}\|_2^2} \mathbf{s}^{(k)} \\ &= (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} + \frac{\mathbf{v}^{(k)}(\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})^T}{\|\mathbf{v}^{(k)}\|_2^2} \mathbf{s}^{(k)} \\ &= (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} + \frac{(\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{v}^{(k)}\|_2^2} \mathbf{v}^{(k)}. \end{aligned}$$

Ebből következik, hogy $(\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} = \alpha \mathbf{v}^{(k)}$ alakú, ahol

$$\begin{aligned} \alpha &= 1 - \frac{(\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{v}^{(k)}\|_2^2} \\ &= 1 - \frac{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{v}^{(k)}\|_2^2} + \frac{(\mathbf{v}^{(k)})^T (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{v}^{(k)}\|_2^2} \\ &= 1 - \alpha^2 \frac{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{M}^{(k)} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}} + \alpha, \end{aligned}$$

és így

$$\begin{aligned} \alpha^2 &= \frac{(\mathbf{s}^{(k)})^T \mathbf{M}^{(k)} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}}{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}} \\ &= \frac{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}}{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}. \end{aligned} \quad (8.28)$$

Mivel a számláló pozitív, hiszen feltettük, hogy $\mathbf{A}^{(k)}$ pozitív definit, ezért α kifejezhető a (8.28) egyenletből, és

$$\mathbf{v}^{(k)} = \frac{1}{\alpha} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} = \left(\frac{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}} \right)^{1/2} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}.$$

Ezt visszahelyettesítve a (8.27) egyenletbe

$$\begin{aligned}\mathbf{M}^{(k+1)} &= \mathbf{M}^{(k)} + \frac{(\mathbf{y}^{(k)} - \frac{1}{\alpha} \mathbf{M}^{(k)} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}) \frac{1}{\alpha} (\mathbf{s}^{(k)})^T \mathbf{M}^{(k)}}{\frac{1}{\alpha^2} \|(\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}\|_2^2} \\ &= \mathbf{M}^{(k)} + \alpha \frac{\mathbf{y}^{(k)} (\mathbf{s}^{(k)})^T \mathbf{M}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}} - \frac{\mathbf{A}^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T \mathbf{M}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}}.\end{aligned}$$

Kis számolással ebből levezethető (2. feladat), hogy

$$\mathbf{A}^{(k+1)} = \mathbf{A}^{(k)} + \frac{\mathbf{y}^{(k)} (\mathbf{y}^{(k)})^T}{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}} - \frac{\mathbf{A}^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T \mathbf{A}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}}. \quad (8.29)$$

Hátra van még azt megmutatni, hogy az iteráció pozitív definit mátrixot generál. Mivel $\mathbf{A}^{(k+1)} = \mathbf{M}^{(k+1)} (\mathbf{M}^{(k+1)})^T$, ezért elegendő azt belátni, hogy $\mathbf{M}^{(k+1)}$ invertálható. A feltevés szerint $\mathbf{M}^{(k)}$ pozitív definit, és ezért invertálható. Ha feltesszük, hogy (8.24) teljesül, akkor $\mathbf{M}^{(k+1)}$ invertálhatóságát könnyen kapjuk a (8.27) képletből a 2.58. tételt alkalmazva. A részletek kidolgozását az olvasóra hagyjuk (3. feladat).

A (8.29) formulát Broyden, Fletcher, Goldfarb és Shanno vezették be 1970-ben, ezért *BFGS-iterációnak* nevezzük. Ez a jelenleg ismert legjobb iterációs formula a Hesse-mátrix közelítésére. Az iteráció kezdeti mátrixának vagy $f''(\mathbf{p}^{(0)})$ -t vagy ennek egy (8.18) másodrendű differencia közelítését célszerű használni. Ha $\mathbf{p}^{(0)}$ elegendően közel van $\mathbf{p}$ -hez, és $f''(\mathbf{p})$ pozitív definit, akkor $f''(\mathbf{p}^{(0)})$, és ezért $\mathbf{A}^{(0)}$ is az lesz.

Végül vizsgáljuk meg, hogy a (8.24) feltétel milyen megszorítást jelent. A Lagrange-féle középértéktételt (2.40. tétel) és a (8.21), (8.22) egyenleteket alkalmazva kapjuk, hogy

$$\begin{aligned}(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)} &= \left(f'(\mathbf{p}^{(k+1)}) - f'(\mathbf{p}^{(k)}) \right)^T (\mathbf{p}^{(k+1)} - \mathbf{p}^{(k)}) \\ &= \sum_{i=1}^n \left(\frac{\partial f_i(\mathbf{p}^{(k+1)})}{\partial x_i} - \frac{\partial f_i(\mathbf{p}^{(k)})}{\partial x_i} \right) (p_i^{(k+1)} - p_i^{(k)}) \\ &= \sum_{i=1}^n \left(\sum_{j=1}^n \frac{\partial^2 f_i(\xi^{(k,i)})}{\partial x_i \partial x_j} (p_j^{(k+1)} - p_j^{(k)}) \right) (p_i^{(k+1)} - p_i^{(k)}).\end{aligned}$$

Ha a $\mathbf{p}^{(k)}$ iteráltak elegendően közel maradnak $\mathbf{p}$ -hez az iteráció közben, akkor $\xi^{(k,i)}$ is $\mathbf{p}$ közelében marad, és ezért f'' folytonossága miatt

$$\begin{aligned}(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)} &\approx \sum_{i=1}^n \left(\sum_{j=1}^n \frac{\partial^2 f_i(\mathbf{p})}{\partial x_i \partial x_j} (p_j^{(k+1)} - p_j^{(k)}) \right) (p_i^{(k+1)} - p_i^{(k)}) \\ &= (\mathbf{p}^{(k+1)} - \mathbf{p}^{(k)})^T f''(\mathbf{p}) (\mathbf{p}^{(k+1)} - \mathbf{p}^{(k)}),\end{aligned}$$

ami pozitív, hiszen $f''(\mathbf{p})$ pozitív definit. Ez a feltétel tehát, ha a sorozat $\mathbf{p}$ -hez tart, $\mathbf{p}$ közelében teljesülni fog. Természetesen ha (8.24) nem teljesül, akkor is definiálható a (8.29) iteráció, csak ekkor $\mathbf{A}^{(k+1)}$ pozitív szemidefinit lesz, nem pozitív definit.

Belátható a következő tétel.

8.17. tétel. Legyen $f \in C^3$, $f'(\mathbf{p}) = 0$, $f''(\mathbf{p})$ pozitív definit. Ekkor létezik olyan $\varepsilon, \delta > 0$, hogy a (8.20)–(8.22), (8.29) iteráció definiált minden k -ra, és superlineárisan konvergál $\mathbf{p}$ -hez, ha $\|\mathbf{p}^{(0)} - \mathbf{p}\|_2 < \varepsilon$ és $\|\mathbf{A}^{(0)} - f''(\mathbf{p})\|_2 < \delta$.

8.8. táblázat. A (8.19) kvázi-Newton módszer BFGS-iterációval

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2}$
0	(2.00000000, 2.00000000)	2.00000e+00	1.80277564	
1	(1.28952043, 0.56127886)	4.59574e-01	0.29593441	0.16415488
2	(1.25102079, 0.70409379)	1.50630e-01	0.32352080	1.09321792
3	(1.19910219, 0.73444653)	8.02473e-02	0.30758228	0.95073416
4	(1.14966546, 0.69907469)	5.06393e-02	0.24905919	0.80973192
5	(1.00399514, 0.50473229)	3.40491e-05	0.00619320	0.02486638
6	(0.99975498, 0.49938607)	6.64526e-07	0.00066102	0.10673251
7	(1.00003118, 0.49997474)	1.46839e-08	0.00004012	0.06070113
8	(1.00001593, 0.50000889)	7.05953e-10	0.00001824	0.45466117
9	(1.00000627, 0.50000724)	8.24492e-11	0.00000958	0.52515860
10	(1.00000015, 0.50000024)	7.49020e-14	0.00000028	0.02901243

8.18. példa. A BFGS-iterációval kaptuk a 8.8. táblázatban szereplő sorozatot az $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényre. Ugyanabból a kezdőértékekből indítottuk a módszert, mint a 8.16. példában. $\square$

Teljes indukcióval ellenőrizhető, hogy a BFGS-módszerrel képzett $\mathbf{A}^{(k)}$ mátrixok $\mathbf{B}^{(k)} := (\mathbf{A}^{(k)})^{-1}$ inverzét a

$$\begin{aligned} \mathbf{B}^{(k+1)} = \mathbf{B}^{(k)} + & \left(1 + \frac{(\mathbf{y}^{(k)})^T \mathbf{B}^{(k)} \mathbf{y}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{y}^{(k)}} \right) \frac{\mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T}{(\mathbf{s}^{(k)})^T \mathbf{y}^{(k)}} \\ & - \frac{\mathbf{s}^{(k)} (\mathbf{y}^{(k)})^T \mathbf{B}^{(k)} + \mathbf{B}^{(k)} \mathbf{y}^{(k)} (\mathbf{s}^{(k)})^T}{(\mathbf{s}^{(k)})^T \mathbf{y}^{(k)}} \end{aligned} \quad (8.30)$$

rekurzív képlettel is kiszámíthatjuk. Ezt az összefüggést használva a (8.20) egyenlet helyettesíthető az

$$\mathbf{s}^{(k)} = -\mathbf{B}^{(k)} f'(\mathbf{p}^{(k)}) \quad (8.31)$$

egyenlettel, és így a módszer alkalmazásakor nincs szükség lineáris egyenletrendszer megoldására vagy mátrix invertálásra.

A BFGS-iteráció levezetéséhez hasonlóan kaphatjuk a DFP-iteráció képletét. Újra $\mathbf{A}^{(k+1)} = \mathbf{M}^{(k+1)} (\mathbf{M}^{(k+1)})^T$ alakban keressük a módosított Hesse-közelítést, de a (8.25)–(8.26) szelő egyenletek helyett most az azzal ekvivalens

$$\begin{aligned} (\mathbf{M}^{(k+1)})^{-1} \mathbf{y}^{(k)} &= \mathbf{v}^{(k)} \\ (\mathbf{M}^{(k+1)})^T \mathbf{v}^{(k)} &= \mathbf{s}^{(k)} \end{aligned}$$

egyenletekből indulunk ki. Ennek megoldását

$$(\mathbf{M}^{(k+1)})^{-1} = (\mathbf{M}^{(k)})^{-1} + \frac{(\mathbf{s}^{(k)} - (\mathbf{M}^{(k)})^{-1} \mathbf{v}^{(k)}) (\mathbf{v}^{(k)})^T}{\|\mathbf{v}^{(k)}\|_2^2}$$

alakban keresve kapjuk, hogy

$$\mathbf{v}^{(k)} = \left(\frac{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}{(\mathbf{y}^{(k)})^T (\mathbf{A}^{(k)})^{-1} \mathbf{y}^{(k)}} \right)^{1/2} (\mathbf{M}^{(k)})^{-1} \mathbf{y}^{(k)},$$

feltéve, hogy a (8.24) teljesül. Ebből a 2.58. tétel alkalmazásával kiszámítható, hogy

$$\begin{aligned} \mathbf{A}^{(k+1)} &= \mathbf{A}^{(k)} + \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})(\mathbf{y}^{(k)})^T + \mathbf{y}^{(k)}(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})^T}{(\mathbf{y}^{(k)})^T\mathbf{s}^{(k)}} \\ &\quad - \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})^T\mathbf{s}^{(k)}}{((\mathbf{y}^{(k)})^T\mathbf{s}^{(k)})^2}\mathbf{y}^{(k)}(\mathbf{y}^{(k)})^T. \end{aligned} \quad (8.32)$$

Ezt a formulát *DFP-iterációnak* nevezzük felfedezői után: Davidon (1959) és Fletcher, Powell (1963). Erre az iterációra is teljesül 8.17 tétellel analóg konvergencia eredmény.

Ellenőrizhető, hogy a DFP-iterációval generált $\mathbf{A}^{(k)}$ mátrix inverze kiszámítható a következő rekurzív módon:

$$(\mathbf{A}^{(k+1)})^{-1} = (\mathbf{A}^{(k)})^{-1} + \frac{\mathbf{s}^{(k)}(\mathbf{s}^{(k)})^T}{(\mathbf{s}^{(k)})^T\mathbf{y}^{(k)}} - \frac{(\mathbf{A}^{(k)})^{-1}\mathbf{y}^{(k)}(\mathbf{y}^{(k)})^T(\mathbf{A}^{(k)})^{-1}}{(\mathbf{y}^{(k)})^T(\mathbf{A}^{(k)})^{-1}\mathbf{y}^{(k)}}. \quad (8.33)$$

8.19. példa. A DFP-iterációt vizsgáltuk a 8.16. és 8.18. példák feladatára. Ez a módszer is a BFGS-iterációhoz hasonlóan gyorsan konvergál. A sorozat a 8.9. táblázatban látható. $\square$

8.9. táblázat. A (8.19) kvázi-Newton módszer DFP-iterációval

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2}$
0	(2.00000000, 2.00000000)	2.00000e+00	1.80277564	
1	(1.28952043, 0.56127886)	4.59574e-01	0.29593441	0.16415488
2	(1.25682024, 0.70394625)	1.61396e-01	0.32794924	1.10818219
3	(1.09891338, 0.59229507)	2.00977e-02	0.13528576	0.41252041
4	(1.01148073, 0.50204318)	6.24877e-04	0.01166112	0.08619621
5	(1.00103666, 0.50022718)	4.77384e-06	0.00106126	0.09100838
6	(1.00001771, 0.50001111)	8.01068e-10	0.00002090	0.01969409
7	(0.99999976, 0.49999958)	2.45621e-13	0.00000049	0.02332123
8	(1.00000001, 0.50000002)	4.22000e-16	0.00000002	0.03601757

Feladatok

1. Alkalmazza az ebben a szakaszban bevezetett kvázi-Newton módszereket a 8.3. szakasz 1. feladatában felsorolt függvényekre!
2. Ellenőrizze a (8.29) formula levezetését!
3. Igazolja, hogy $\mathbf{M}^{(k+1)}$ invertálható, ha (8.24) teljesül!
4. Igazolja a (8.30) rekurzív összefüggést!
5. Dolgozza ki a DFP-iteráció levezetésének részleteit!
6. Igazolja a (8.33) rekurzív összefüggést!