

Numerikus analízis

8. Szélsőértékszámítás

Ferenc Hartung

Pannon Egyetem
Matematika Tanszék



2026

8.1. Analízis előismeretek

Legyen $f: \mathbb{R}^n \rightarrow \mathbb{R}$.

$$f''(\mathbf{x}) := \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_2^2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n}(\mathbf{x}) \\ \vdots & \vdots & & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_n \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_n^2}(\mathbf{x}) \end{pmatrix}$$

Tétel

Legyen $f: \mathbb{R}^n \rightarrow \mathbb{R}$ parciálisan differenciálható minden változója szerint. Ekkor ha f -nek létezik lokális szélsőértéke az $\mathbf{a}$ pontban, akkor $\frac{\partial f(\mathbf{a})}{\partial x_i} = 0$ teljesül minden $i = 1, \dots, n$ -re.

Ha $f \in C^2$, és valamely $\mathbf{a}$ pontban $f'(\mathbf{a}) = \mathbf{0}$, továbbá az $f''(\mathbf{a})$ Hesse-mátrix pozitív (negatív) definit, akkor f -nek lokális minimuma (maximuma) van $\mathbf{a}$ -ban.

Kétváltozós függvényekre az előbbi tétel speciális esetekén kapjuk:

Tétel

Legyen $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, $f \in C^2$. Ekkor ha f -nek létezik lokális szélsőértéke az (a, b) pontban, akkor

$$\frac{\partial f}{\partial x}(a, b) = 0, \quad \frac{\partial f}{\partial y}(a, b) = 0 \quad (1)$$

teljesül.




Fordítva, ha valamely (a, b) -re (1) teljesül, továbbá

$$D(a, b) := \frac{\partial^2 f}{\partial x^2}(a, b) \cdot \frac{\partial^2 f}{\partial y^2}(a, b) - \left(\frac{\partial^2 f}{\partial x \partial y}(a, b) \right)^2 > 0$$

akkor f -nek létezik lokális szélsőértéke (a, b) -ben, mégpedig lokális maximuma, ha $\frac{\partial^2 f}{\partial x^2}(a, b) < 0$ ill. lokális minimuma, ha $\frac{\partial^2 f}{\partial x^2}(a, b) > 0$. Ha $D(a, b) < 0$, akkor f -nek nincs szélsőértéke (a, b) -ben.



8.2. Aranymetszés szerinti keresés módszere

Legyen $f: [a, b] \rightarrow \mathbb{R}$ folytonos, és feltesszük, hogy f **unimodális**, azaz f -nek egyértelmű lokális minimuma van $[a, b]$ -ben.



unimodális függvények

Az **arany metszés szerinti keresés módszernél**, az intervallumfelezés módszeréhez hasonlóan, egyre szűkebb és szűkebb intervallumokra határoljuk be a függvény minimumhelyét: Legyen $a < y < x < b$. Ha $f(x) > f(y)$, akkor $p \in [a, x]$, ellenkező esetben $p \in [y, b]$ teljesül. Ezután az $[a, x]$ illetve $[y, b]$ intervallummal folytatjuk az eljárást.



1. ötlet: Az x és y pontokat úgy választjuk, hogy az $[a, x]$ és $[y, b]$ intervallum hossza azonos legyen:

$$x - a = b - y = r(b - a)$$


valamely $0 < r < 1$ -re. Ekkor

$$x = a + r(b - a), \quad y = a + (1 - r)(b - a) \quad (2)$$

alakú. Az $x > y$ feltételből kapjuk, hogy $0.5 < r < 1$ kell legyen.

Jelölje $[a', b']$ a következő intervallumot. Válasszuk az új osztópontokat, x' -t és y' -t a (2) szabály szerint, és $f(x')$ és $f(y')$ összehasonlításával határozzuk meg a következő intervallumot.

2. ötlet: Az aranymetszés szerinti keresés módszere úgy választja meg r -t, hogy az új x' , y' osztópontok közül az egyik egyezzen meg egy előző osztóponttal, azért hogy minden lépésben csak egy új függvényértéket kelljen kiértékelni.



Tegyük fel, hogy $[a', b'] = [y, b]$. Ekkor $y' = x$.

$$\begin{aligned} a + r(b - a) &= y' \\ &= a' + (1 - r)(b' - a') \\ &= y + (1 - r)(b - y) \\ &= a + (1 - r)(b - a) + (1 - r)(b - a - (1 - r)(b - a)), \end{aligned}$$

és így

$$r = 1 - r + (1 - r)(1 - (1 - r)),$$

amiből

$$r^2 + r - 1 = 0. \quad (3)$$

Ennek pozitív megoldása $r = (\sqrt{5} - 1)/2 \approx 0.61834$. Ez az aranymetszés arányossági tényezője: r teljesíti az

$$\frac{r}{1-r} = \frac{1}{r}$$

egyenlet.



Ha $[a', b'] = [a, x]$, akkor legyen r olyan, hogy $x' = y$ teljesüljön. Megmutatható, hogy ez a követelmény is a (3) egyenlethez vezet.

Tétel

Legyen $f \in C(a, b)$ unimodális függvény. Ekkor az aranymetszés szerinti keresés módszere konvergál az f függvény minimumhelyéhez.

Könnyű ellenőrizni, hogy az aranymetszés szerinti keresés módszere n lépése után az intervallum hossza $(b - a)r^n$ lesz. Így az ε tolerancia értéket

$$n \geq \frac{\log \frac{\varepsilon}{b-a}}{\log r} \quad (4)$$

lépésben éri el.

Példa



Keressük meg az $f(x) = x^2 - 0.8x + 1$ függvény minimumhelyét! Könnyű kiszámolni, hogy a függvény a minimumát a $p = 0.4$ pontban veszi fel. Az aranymetszés szerinti keresés módszerét alkalmaztuk az adott függvényre a $[-1, 2]$ kezdeti intervallumot és az $\varepsilon = 0.005$ tolerancia értéket használva. A (4) formula szerint $n \geq 13.29337586$ lépés kell az előírt tolerancia eléréséhez. Az algoritmus az utolsó intervallum felezőpontját, 0.3995535068 -t adja meg, mint a minimumhely közelítő értékét.

Példa folyt.



 Aranymetszés szerinti keresés módszere, $f(x) = x^2 - 0.8x + 1$

k	$[a_k, b_k]$	y_k	x_k
0	$[-1.0000000000, 2.0000000000]$	0.1458980338	0.8541019662
1	$[-1.0000000000, 0.8541019662]$	-0.2917960675	0.1458980338
2	$[-0.2917960675, 0.8541019662]$	0.1458980338	0.4164078650
3	$[0.1458980338, 0.8541019662]$	0.4164078650	0.5835921350
4	$[0.1458980338, 0.5835921350]$	0.3130823038	0.4164078650
5	$[0.3130823038, 0.5835921350]$	0.4164078650	0.4802665738
6	$[0.3130823038, 0.4802665738]$	0.3769410125	0.4164078650
7	$[0.3769410125, 0.4802665738]$	0.4164078650	0.4407997213
8	$[0.3769410125, 0.4407997213]$	0.4013328688	0.4164078650
9	$[0.3769410125, 0.4164078650]$	0.3920160087	0.4013328688
10	$[0.3920160087, 0.4164078650]$	0.4013328688	0.4070910050
11	$[0.3920160087, 0.4070910050]$	0.3977741449	0.4013328688
12	$[0.3977741449, 0.4070910050]$	0.4013328688	0.4035322811
13	$[0.3977741449, 0.4035322811]$	0.3999735572	0.4013328688
14	$[0.3977741449, 0.4013328688]$	0.3991334565	0.3999735572



8.3. Szimplex módszer



$$f(x, y) = 4 - 3x^2 - y^2$$



$$f(x, y) = 4 - 3x^2 - y^2 \text{ szintvonalai}$$




Egy n -dimenziós **szimplexen** olyan $n + 1$ darab n -dimenziós vektor konvex burkát, azaz az

$$\{\alpha_0 \mathbf{x}^{(0)} + \cdots + \alpha_n \mathbf{x}^{(n)} : 0 \leq \alpha_i \leq 1, \quad \alpha_0 + \cdots + \alpha_n \leq 1\}$$


halmazt értjük, ahol az $\mathbf{x}_1 - \mathbf{x}_0, \mathbf{x}_2 - \mathbf{x}_0, \dots, \mathbf{x}_n - \mathbf{x}_0$ vektorok lineárisan függetlenek. Ekkor az $\mathbf{x}^{(0)}, \dots, \mathbf{x}^{(n)}$ vektorokat a szimplex csúcspontjainak hívjuk.



1D szimplex:
szakasz



2D szimplex:
háromszög



3D szimplex:
tetraéder

szimplex módszer: Vegyünk fel kiindulásként egy n -dimenziós szimplexet. Tegyük fel, hogy minden lépésben a csúcspontokat úgy indexeljük, hogy

$$f(\mathbf{x}^{(0)}) \leq f(\mathbf{x}^{(1)}) \leq \dots \leq f(\mathbf{x}^{(n)}).$$

Ekkor $\mathbf{x}^{(n)}$ a „legrosszabb”, és $\mathbf{x}^{(0)}$ a „legjobb” csúcspont.

1. lépés: A szimplex legrosszabb pontját tükrözzük az $\mathbf{x}^{(n)}$ ponttal szemben fekvő oldal középpontjára, azaz a többi csúcspont

$$\mathbf{x}_c := \frac{1}{n} \sum_{i=0}^{n-1} \mathbf{x}^{(i)}$$

súlypontjára. A tükrözött pont koordinátáit az

$$\mathbf{x}_r = 2\mathbf{x}_c - \mathbf{x}^{(n)}$$

képlettel számíthatjuk ki.

2. lépés: Ha $f(\mathbf{x}_r)$ kisebb, mint $f(\mathbf{x}^{(n)})$, akkor a tükrözést elfogadjuk, ellenkező esetben viszont a legjobb csúcspontból fele akkorára zsugorítjuk a szimplexet: a többi csúcspontot az

$$\mathbf{x}^{(i)} \leftarrow \mathbf{x}^{(0)} + \frac{1}{2}(\mathbf{x}^{(i)} - \mathbf{x}^{(0)}), \quad i = 1, \dots, n$$

képlettel számoljuk újra.

A kapott (tükrözött vagy zsugorított) szimplexszel megismételjük az eljárást.

Az előbbi iterációs módszerhez többféle megállási feltételt, illetve feltétel kombinációt adhatunk meg.

1. Az eljárás akkor érjen véget, ha a szimplex egy előre megadott méretnél kisebb lesz. A szimplex méretét definiálhatjuk például a leghosszabb éle hosszaként, azaz a $\max\{\|\mathbf{x}^{(i)} - \mathbf{x}^{(j)}\| : i, j = 0, \dots, n\}$ képlettel.
2. A szimplexek súlypontjaiban felvett f_k függvényérték sorozatára alkalmazzuk az $|f_{k+1} - f_k| < \varepsilon$ feltételt.
3. Legyen $\bar{f}$ a csúcspontokban felvett függvényértékek átlaga, σ pedig a szórása, azaz

$$\bar{f} = \frac{1}{n+1} \sum_{i=0}^n f(\mathbf{x}^{(i)}), \quad \sigma = \sqrt{\frac{1}{n+1} \sum_{i=0}^n (f(\mathbf{x}^{(i)}) - \bar{f})^2}.$$

Ekkor addig folytatjuk az iterációt, amíg σ kisebb nem lesz mint egy előre megadott tolerancia érték.

A függvény minimumhelyét az algoritmus utolsó lépésében kapott szimplex súlypontjával szokás közelíteni.

Példa

Keressük meg az

$$f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$$

függvény minimumhelyét! Könnyen látható, hogy a függvénynek az $(1, 0.5)$ pontban van (globális) minimuma. A szimplex módszert alkalmaztuk a feladat megoldására a $(-2, 4)$, $(-1, 4)$ és $(-1.5, 5)$ kezdeti háromszögből kiindulva. Az első 30 lépésben kapott háromszögeket és a csúcspontokhoz tartozó függvényértékeket az alábbi táblázatban soroltuk fel. Az ábrán láthatók f szintvonalai és az első 22 lépésekben kapott háromszögek. A 30. háromszög középpontja, $(0.9688, 0.4583)$, jó közelítése a pontos minimumhelynek. Az ebben a pontban felvett függvényérték 0.00243 , ami közel van a pontos minimum értékhez, 0 -hoz.


Példa folyt.

Szimplex módszer, $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$

k	$\mathbf{x}^{(k,1)}$	$\mathbf{x}^{(k,2)}$	$\mathbf{x}^{(k,3)}$	$f(\mathbf{x}^{(k,1)})$	$f(\mathbf{x}^{(k,2)})$	$f(\mathbf{x}^{(k,3)})$
0	(-1.000, 4.000)	(-2.000, 4.000)	(-1.500, 5.000)	57.000	34.000	72.563
1	(-2.000, 4.000)	(-1.000, 4.000)	(-1.500, 3.000)	34.000	57.000	26.562
2	(-1.500, 3.000)	(-2.000, 4.000)	(-2.500, 3.000)	26.562	34.000	24.562
3	(-2.500, 3.000)	(-1.500, 3.000)	(-2.000, 2.000)	24.562	26.562	18.000
4	(-2.000, 2.000)	(-2.250, 2.500)	(-1.750, 2.500)	18.000	21.129	18.879
5	(-2.000, 2.000)	(-1.750, 2.500)	(-1.500, 2.000)	18.000	18.879	15.562
6	(-1.500, 2.000)	(-2.000, 2.000)	(-1.750, 1.500)	15.562	18.000	15.129
7	(-1.750, 1.500)	(-1.500, 2.000)	(-1.250, 1.500)	15.129	15.562	12.191
⋮						
23	(0.875, 0.250)	(0.750, 0.250)	(0.812, 0.375)	0.102	0.129	0.078
24	(0.812, 0.375)	(0.875, 0.250)	(0.938, 0.375)	0.078	0.102	0.024
25	(0.938, 0.375)	(0.812, 0.375)	(0.875, 0.500)	0.024	0.078	0.086
26	(0.938, 0.375)	(0.875, 0.375)	(0.906, 0.438)	0.024	0.031	0.020
27	(0.906, 0.438)	(0.938, 0.375)	(0.969, 0.438)	0.020	0.024	0.006
28	(0.969, 0.438)	(0.906, 0.438)	(0.938, 0.500)	0.006	0.020	0.022
29	(0.969, 0.438)	(0.938, 0.438)	(0.953, 0.469)	0.006	0.008	0.005
30	(0.953, 0.469)	(0.969, 0.438)	(0.984, 0.469)	0.005	0.006	0.001

a súlypont: (0.9688, 0.4583), a függvényérték: 0.00243

Példa folyt.



Szimplex módszer (22 lépés).

A szimplex módszernek egy módosított változata a **Nelder–Mead-módszer**. Ennél a módszernél a szimplexet tükrözzük, illetve megnyújtjuk vagy zsugorítjuk aszerint, hogy milyen értékeket vesz fel a függvény a csúcspontokban. Feltesszük, hogy minden egyes lépésben a csúcspontokat úgy indexezzük, hogy a függvényértékek növekvő sorrendben legyenek, azaz $f(\mathbf{x}^{(0)}) \leq f(\mathbf{x}^{(1)}) \leq \dots \leq f(\mathbf{x}^{(n)})$. Ekkor $\mathbf{x}^{(n)}$ a legrosszabb csúcspont.

1. lépés: Tükrözzük az $\mathbf{x}^{(n)}$ pontot a szemben fekvő oldal

$$\mathbf{x}_c = \frac{1}{n} \sum_{i=0}^{n-1} \mathbf{x}^{(i)}$$

súlypontjára. Legyen a tükrözött pont $\mathbf{x}_r = 2\mathbf{x}_c - \mathbf{x}^{(n)}$.

2. lépés: Tekintsük az $f(\mathbf{x}_r)$ függvényértéket. Három esetet különböztetünk meg:

- (i) $f(\mathbf{x}^{(0)}) < f(\mathbf{x}_r) < f(\mathbf{x}^{(n-1)})$,
- (ii) $f(\mathbf{x}_r) \leq f(\mathbf{x}^{(0)})$, azaz $\mathbf{x}_r$ lenne az új legjobb pont, és
- (iii) $f(\mathbf{x}_r) \geq f(\mathbf{x}^{(n-1)})$, azaz $\mathbf{x}_r$ lenne az új legrosszabb pont.

Case (i), $f(\mathbf{x}^{(0)}) < f(\mathbf{x}_r) < f(\mathbf{x}^{(n-1)})$:

$\mathbf{x}^{(n)}$ -t $\mathbf{x}_r$ -re kicseréljük (elfogadtuk a tükrözést), és folytatjuk az iterációt.

Case (ii), $f(\mathbf{x}_r) \leq f(\mathbf{x}^{(0)})$:

először megpróbáljuk az $\mathbf{x}_r$ irányban megnyújtani egy kicsit a szimplexet, hátha még jobb pontot kapunk. Legyen

$$\mathbf{x}_e := \mathbf{x}_c + \alpha(\mathbf{x}_r - \mathbf{x}_c),$$

ahol $\alpha > 1$ egy rögzített szám (egy paraméter a módszerben).

Ha ekkor $f(\mathbf{x}_e) < f(\mathbf{x}^{(0)})$ teljesül, akkor a megnyújtást sikeresnek ítéljük, és $\mathbf{x}^{(n)}$ -t $\mathbf{x}_e$ -re cseréljük ki.

Ellenkező esetben viszont $\mathbf{x}^{(n)}$ -t $\mathbf{x}_r$ -re cseréljük ki, azaz tükrözzük, de nem nyújtjuk meg a szimplexet.

Case (iii), $f(\mathbf{x}_r) \geq f(\mathbf{x}^{(n-1)})$:

Azt gondoljuk, hogy túl messze tükröztük $\mathbf{x}^{(n)}$ -t, így megpróbáljuk zsugorítani a szimplexet. Legyen

$$\mathbf{x}_z := \begin{cases} \mathbf{x}_c - \beta(\mathbf{x}_r - \mathbf{x}_c), & \text{ha } f(\mathbf{x}^{(n)}) < f(\mathbf{x}_r), \\ \mathbf{x}_c + \beta(\mathbf{x}_r - \mathbf{x}_c), & \text{ha } f(\mathbf{x}^{(n)}) \geq f(\mathbf{x}_r), \end{cases}$$

ahol $0 < \beta < 1$ egy újabb paraméter.

Ha $f(\mathbf{x}_z) < \min\{f(\mathbf{x}^{(n)}), f(\mathbf{x}_r)\}$, akkor $\mathbf{x}^{(n)}$ -t $\mathbf{x}_z$ -vel cseréljük fel.

Ellenkező esetben viszont a szimplexet a legjobb pontjából, $\mathbf{x}^{(0)}$ -ból a felére zsugorítjuk össze:

$$\mathbf{x}^{(i)} \leftarrow \mathbf{x}^{(0)} + \frac{1}{2}(\mathbf{x}^{(i)} - \mathbf{x}^{(0)}), \quad i = 1, \dots, n.$$

Ismételjük meg az 1. és 2. lépéseket.


Példa

A Nelder–Mead-módszert alkalmaztuk az $\alpha = 1.4$ és $\beta = 0.7$ paraméter értékekkel az


$$f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$$

függvény minimumhelyének keresésére. Most is a $(-2, 4)$, $(-1, 4)$ és $(-1.5, 5)$ háromszögből indultunk ki. A kapott sorozat első 17 tagja látható az alábbi táblázatban, illetve az alábbi ábrákon. A 17. háromszög középpontja $(1.0071, 0.5929)$, a hozzá tartozó függvényérték pedig 0.0295. Látható, hogy ez a módszer sokkal gyorsabban konvergál a minimumhelyhez, mint a szimplex módszer.


Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.




Példa folyt.



Példa folyt.



Példa folyt.




Példa folyt.

Nelder–Mead-módszer, $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$, $\alpha = 1.4$, $\beta = 0.7$


k	$\mathbf{x}^{(k,1)}$	$\mathbf{x}^{(k,2)}$	$\mathbf{x}^{(k,3)}$	$f(\mathbf{x}^{(k,1)})$	$f(\mathbf{x}^{(k,2)})$	$f(\mathbf{x}^{(k,3)})$
0	(-1.000, 4.000)	(-2.000, 4.000)	(-1.500, 5.000)	57.000	34.000	72.563
1	(-2.000, 4.000)	(-1.000, 4.000)	(-1.500, 2.600)	34.000	57.000	21.203
2	(-1.500, 2.600)	(-2.000, 4.000)	(-2.500, 2.600)	21.203	34.000	25.603
3	(-1.500, 2.600)	(-2.500, 2.600)	(-2.000, 1.200)	21.203	25.603	20.560
4	(-2.000, 1.200)	(-1.500, 2.600)	(-0.700, 0.920)	20.560	21.203	7.602
5	(-0.700, 0.920)	(-2.000, 1.200)	(-1.200, -0.480)	7.602	20.560	15.440
6	(-0.700, 0.920)	(-1.200, -0.480)	(0.520, -1.152)	7.602	15.440	7.088
7	(0.520, -1.152)	(-0.700, 0.920)	(1.464, 0.394)	7.088	7.602	2.270
8	(1.464, 0.394)	(0.520, -1.152)	(-0.192, 0.530)	2.270	7.088	3.891
9	(1.464, 0.394)	(-0.192, 0.530)	(0.555, -0.668)	2.270	3.891	3.097
10	(1.464, 0.394)	(0.555, -0.668)	(0.168, 0.330)	2.270	3.097	1.783
11	(0.168, 0.330)	(1.464, 0.394)	(0.999, 1.083)	1.783	2.270	1.362
12	(0.999, 1.083)	(0.168, 0.330)	(1.200, 0.487)	1.362	1.783	0.296
13	(1.200, 0.487)	(0.999, 1.083)	(0.448, 0.467)	0.296	1.362	1.147
14	(1.200, 0.487)	(0.448, 0.467)	(0.648, -0.129)	0.296	1.147	0.707
15	(1.200, 0.487)	(0.648, -0.129)	(0.591, 0.380)	0.296	0.707	0.505
16	(1.200, 0.487)	(0.591, 0.380)	(1.068, 0.828)	0.296	0.505	0.274
17	(1.068, 0.828)	(1.200, 0.487)	(0.754, 0.464)	0.274	0.296	0.251

súlypont: (1.0071, 0.5929), függvényérték: 0.0295

8.4. Gradiens módszer



$$f(x, y) = 4 - 3x^2 - y^2$$



$$f(x, y) = 4 - 3x^2 - y^2, \quad \mathbf{p} = (0.5, 0.5), \quad \mathbf{u} = -f'(\mathbf{p})$$

Theorem

Legyen $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ folytonosan differenciálható. Ekkor az $f'(\mathbf{p})$ gradiens vektor merőleges az f függvény $\mathbf{p}$ ponthoz tartozó szintvonalára, azaz a szintvonal $\mathbf{p}$ ponthoz tartozó érintőjére.

Bizonyítás

Legyen

$$\gamma(t) = \begin{pmatrix} x(t) \\ y(t) \end{pmatrix}$$

az f függvény $\gamma(t_0) = \mathbf{p}$ ponthoz tartozó szintvonalának paraméteres előállítása, és legyen $f(\mathbf{p}) = c$. Ekkor

$$f(x(t), y(t)) = f(\gamma(t)) = c, \quad \text{minden } t\text{-re,}$$


így

$$0 = \frac{d}{dt} f(\gamma(t)) = f'(\gamma(t))^T \gamma'(t), \quad t \in \mathbb{R}.$$


Ezért $t = t_0$ -re kapjuk

$$f'(\mathbf{p})^T \gamma'(t_0) = 0,$$


tehát $f'(\mathbf{p})$ merőleges a $\mathbf{p}$ ponthoz tartozó érintő irányvektorára, azaz a $\gamma'(t_0) = (x'(t_0), y'(t_0))^T$ vektorra.




$$f(x, y) = 4 - 3x^2 - y^2, \quad \mathbf{p} = (0.5, 0.5), \quad \mathbf{u} = -f'(\mathbf{p})$$



$$f(x, y) = 4 - 3x^2 - y^2, \quad \mathbf{p} = (0.5, 0.5), \quad \mathbf{u} = -f'(\mathbf{p})$$



$$f(x, y) = 4 - 3x^2 - y^2$$



$$f(x, y) = 4 - 3x^2 - y^2$$

Tekintsünk egy $f: \mathbb{R}^n \rightarrow \mathbb{R}$ függvényt. Analízisből ismert tétel szerint egy $\mathbf{p}$ pontban az f függvény a $-f'(\mathbf{p})$ irányban csökken a leggyorsabban:

Tétel

Legyen $f \in C^1$. Ekkor a

$$\lim_{t \rightarrow 0+} \frac{f(\mathbf{p} + t\mathbf{u}) - f(\mathbf{p})}{t}, \quad \|\mathbf{u}\|_2 = 1$$

iránymenti deriváltak minimuma az $\mathbf{u} = -f'(\mathbf{p})/\|f'(\mathbf{p})\|_2$ irányban van.

Egy $\mathbf{u}$ irányt az f függvény $\mathbf{p}$ pontbeli **lejtőjének** nevezzük, ha létezik olyan $\delta > 0$, hogy $f(\mathbf{p} + t\mathbf{u}) < f(\mathbf{p})$ minden $0 < t < \delta$ -ra, azaz a függvény csökken a $\mathbf{p}$ pontból az $\mathbf{u}$ irány mentén indulva. A tételt úgy is megfogalmazhatjuk, hogy az f függvénynek a $\mathbf{p}$ pontban a $-f'(\mathbf{p})$ irányban legmeredekebb a lejtője.

A **gradiens módszer** szerint egy $\mathbf{p}^{(0)}$ kezdeti pontból a negatív gradiensvektor irányában kell elmozdulni. Szokás az előbbieket miatt ezt a **legmeredekebb lejtő módszerének** is nevezni. A módszer általános képlete ezért:

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \alpha_k f'(\mathbf{p}^{(k)}), \quad (5)$$

ahol α_k a lépésközt meghatározó szorzótényező.

A legegyszerűbb esetben a lépésköz állandó. Legyen h rögzített, és használjuk az

$$\alpha_k = \frac{h}{\|f'(\mathbf{p}^{(k)})\|_2}$$

számot.

Egy másik változatban úgy választjuk meg a lépésközt, hogy

$$\phi_k(\alpha_k) = \min_{t \in \mathbb{R}} \phi_k(t)$$

legyen, ahol

$$\phi_k(t) := f\left(\mathbf{p}^{(k)} - t f'(\mathbf{p}^{(k)})\right). \quad (6)$$

Ekkor minden egyes lépésben a gradiensvektor által meghatározott egyenes mentén egy egyváltozós függvényt kell minimalizálni. Ez utóbbi módon választott lépésközt használó gradiens módszert **optimális gradiens módszernek**

Az optimális gradiens módszernél a gradiensvektorral párhuzamos egyenes mentén egy olyan pontig lépünk, ahol az egyenes érint egy szintvonalat. Abból a pontból pedig a pontbeli gradiensvektorral párhuzamosan lépünk tovább. Ebből következik, hogy az optimális gradiens módszernél az egymás utáni lépések irányai merőlegesek egymásra.


Megmutatható, hogy az optimális gradiens módszer lokálisan lineárisan konvergens. A sorozat aszimptotikus hibakonstansa néha közel van 1-hez, azaz a konvergencia lassú is lehet.

Példa

Tekintsük újra az $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényt. Először az $\alpha_k = 0.3 / \|f'(\mathbf{p}^{(k)})\|_2$ lépésközzel futtadjuk a gradiens módszert, két kezdeti pontból indítva a módszert: a $(-1, 4)$ kezdeti értékből (piros karikák) és a $(0.5, 3.5)$ kezdeti értékből (lila karikák). A kapott sorozatok első 25 tagja a következő ábrán látható. A sorozatok lassan közelítik meg az $(1, 0.5)$ minimumhelyet (kék pont), és annak közelében oszcillálnak. Vegyük észre, hogy ahogy az az analízisből ismert, a gradiensvektor merőleges a ponthoz tartozó szintvonalra, így a gradiens módszer sorozata mindig a szintvonalra merőleges irányban mozdul el.


Ezután az optimális gradiens módszert alkalmaztuk a $(-1, 4)$ és az $(0.5, 3.5)$ kezdőpontból indulva. A két sorozat első 3 illetve 12 tagját a következő ábrán láthatjuk. Az első sorozat gyorsan a minimumhely közelébe került. A második is gyorsan a minimumhelyet tartalmazó hosszúkás „völgybe” került, de ezután ott csak lassan, cikcakkban haladt a minimumhely felé.

Példa folyt.



Gradiens módszer konstans lépésközt használva.

Példa folyt.



Optimális gradiens módszer.

Ha f gradiensvektorát nem tudjuk vagy nem akarjuk kiszámolni (túl sok műveletet igényel), használhatjuk (5) következő változatát:

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \alpha_k \mathbf{v}^{(k)}, \quad (7)$$

ahol a $\mathbf{v}^{(k)}$ vektor i -edik komponensét a

$$v_i^{(k)} = \frac{1}{h} \left(f(\mathbf{p}^{(k)} + h\mathbf{e}^{(i)}) - f(\mathbf{p}^{(k)}) \right), \quad i = 1, \dots, n$$

képlettel számoljuk ($\mathbf{e}^{(i)}$ az i -edik egységvektor).

8.5. Lineáris egyenletrendszerek megoldása gradiens módszerrel

Legyen $\mathbf{A} \in \mathbb{R}^{n \times n}$ **szimmetrikus** mátrix, azaz $\mathbf{A}^T = \mathbf{A}$, $\mathbf{b} \in \mathbb{R}^n$, $c \in \mathbb{R}$, és tekintsük a

$$g: \mathbb{R}^n \rightarrow \mathbb{R}, \quad g(\mathbf{x}) := \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} + c \quad (8)$$

alakú kvadratikus függvényt. Az

$$\mathbf{A} = (a_{ij}), \quad \mathbf{x} = (x_1, \dots, x_n)^T, \quad \mathbf{b} = (b_1, \dots, b_n)^T$$

jelöléseket használva felírhatjuk g -t a következő alakban:

$$g(x_1, \dots, x_n) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i + c.$$

Számítsuk ki a $\frac{\partial g}{\partial x_i}$ parciális deriváltat. A feltevés szerint $a_{ij} = a_{ji}$, ezért

$$\frac{\partial g}{\partial x_i}(x_1, \dots, x_n) = \frac{1}{2} \sum_{j=1}^n (a_{ij} x_j + a_{ji} x_j) - b_i = \sum_{j=1}^n a_{ij} x_j - b_i,$$

azaz vektoriális alakban

$$g'(\mathbf{x}) = \left(\frac{\partial g}{\partial x_1}(\mathbf{x}), \dots, \frac{\partial g}{\partial x_n}(\mathbf{x}) \right)^T = \mathbf{A}\mathbf{x} - \mathbf{b}. \quad (9)$$

Így ha $\mathbf{A}$ invertálható, akkor g -nek pontosan egy kritikus pontja van, amely az $\mathbf{A}\mathbf{x} = \mathbf{b}$ egyenlet megoldása. Legyen $\bar{\mathbf{x}}$ a g függvény kritikus pontja, azaz $\mathbf{A}\bar{\mathbf{x}} = \mathbf{b}$, és $\mathbf{x} = \bar{\mathbf{x}} + \Delta\mathbf{x}$.

$$\begin{aligned} g(\bar{\mathbf{x}} + \Delta\mathbf{x}) &= \frac{1}{2}(\bar{\mathbf{x}} + \Delta\mathbf{x})^T \mathbf{A}(\bar{\mathbf{x}} + \Delta\mathbf{x}) - \mathbf{b}^T(\bar{\mathbf{x}} + \Delta\mathbf{x}) + c \\ &= \frac{1}{2}\bar{\mathbf{x}}^T \mathbf{A}\bar{\mathbf{x}} + \frac{1}{2}\bar{\mathbf{x}}^T \mathbf{A}\Delta\mathbf{x} + \frac{1}{2}(\Delta\mathbf{x})^T \mathbf{A}\bar{\mathbf{x}} + \frac{1}{2}(\Delta\mathbf{x})^T \mathbf{A}\Delta\mathbf{x} \\ &\quad - \mathbf{b}^T \bar{\mathbf{x}} - \mathbf{b}^T \Delta\mathbf{x} + c. \end{aligned}$$

Ebből kapjuk az $\mathbf{A} = \mathbf{A}^T$, $\bar{\mathbf{x}}^T \mathbf{A}\Delta\mathbf{x} = (\Delta\mathbf{x})^T \mathbf{A}\bar{\mathbf{x}}$, $\mathbf{b}^T \Delta\mathbf{x} = (\Delta\mathbf{x})^T \mathbf{b}$ és az $\mathbf{A}\bar{\mathbf{x}} = \mathbf{b}$ összefüggéseket felhasználva, hogy

$$\begin{aligned} g(\bar{\mathbf{x}} + \Delta\mathbf{x}) &= \frac{1}{2}\bar{\mathbf{x}}^T \mathbf{A}\bar{\mathbf{x}} - \mathbf{b}^T \bar{\mathbf{x}} + (\Delta\mathbf{x})^T (\mathbf{A}\bar{\mathbf{x}} - \mathbf{b}) + \frac{1}{2}(\Delta\mathbf{x})^T \mathbf{A}\Delta\mathbf{x} + c \\ &= g(\bar{\mathbf{x}}) + \frac{1}{2}(\Delta\mathbf{x})^T \mathbf{A}\Delta\mathbf{x}. \end{aligned}$$

Ezért

$$g(\bar{\mathbf{x}} + \Delta \mathbf{x}) - g(\bar{\mathbf{x}}) = \frac{1}{2}(\Delta \mathbf{x})^T \mathbf{A} \Delta \mathbf{x}. \quad (10)$$

Ha $\mathbf{A}$ pozitív definit mátrix, akkor $g(\bar{\mathbf{x}} + \Delta \mathbf{x}) - g(\bar{\mathbf{x}}) > 0$ minden $\Delta \mathbf{x} \neq \mathbf{0}$ vektorra, azaz $\bar{\mathbf{x}}$ minimalizálja a g függvényt. Ehhez hasonlóan, ha $\mathbf{A}$ negatív definit, akkor a (10) egyenletből következik, hogy g -nek maximuma van $\bar{\mathbf{x}}$ -ben. Pozitív ill. negatív definit mátrixok invertálhatók.

Tétel

Legyen $\mathbf{A}$ szimmetrikus. Ekkor a $g(\mathbf{x}) := \frac{1}{2}\mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} + c$ kvadratikus függvény gradiensvektora $g'(\mathbf{x}) = \mathbf{A} \mathbf{x} - \mathbf{b}$. Ha $\mathbf{A}$ pozitív (negatív) definit, akkor g -nek létezik globális minimuma (maximuma), amelyet a függvény az $\mathbf{x} = \mathbf{A}^{-1}\mathbf{b}$ pontban vesz fel.

Következmény

a egy kvadratikus függvénynek egy pontban lokális minimuma (maximuma) van, akkor ott a függvénynek globális minimuma (maximuma) is van.

Ha $\mathbf{A}$ egy szimmetrikus pozitív definit mátrix, akkor az

$$\mathbf{Ax} = \mathbf{b}$$

lineáris egyenletrendszert megoldhatjuk úgy, hogy definiáljuk a g kvadratikus függvényt a (8) képlettel, és optimális gradiens módszerrel minimalizáljuk azt. Definiáljuk tehát a

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \alpha_k \mathbf{v}^{(k)}$$

sorozatot, ahol

$$\mathbf{v}^{(k)} = g'(\mathbf{p}^{(k)}) = \mathbf{Ap}^{(k)} - \mathbf{b}.$$

α_k -t az optimális gradiens módszer definíciójának megfelelően a $\phi_k(t) = g(\mathbf{p}^{(k)} - t\mathbf{v}^{(k)})$ egyváltozós függvény minimumhelyének választjuk. A ϕ_k függvény egy másodfokú polinom, hiszen

$$\begin{aligned} \phi_k(t) &= \frac{1}{2} \left(\mathbf{p}^{(k)} - t\mathbf{v}^{(k)} \right)^T \mathbf{A} \left(\mathbf{p}^{(k)} - t\mathbf{v}^{(k)} \right) - \mathbf{b}^T \left(\mathbf{p}^{(k)} - t\mathbf{v}^{(k)} \right) + c \\ &= t^2 \frac{1}{2} \left(\mathbf{v}^{(k)} \right)^T \mathbf{A} \mathbf{v}^{(k)} - t \left(\mathbf{v}^{(k)} \right)^T (\mathbf{Ap}^{(k)} - \mathbf{b}) \\ &\quad + \frac{1}{2} \left(\mathbf{p}^{(k)} \right)^T \mathbf{Ap}^{(k)} - \mathbf{b}^T \mathbf{p}^{(k)} + c. \end{aligned}$$

Ezért ϕ_k minimumhelyét explicit módon meg tudjuk adni:

$$\alpha_k = \frac{(\mathbf{v}^{(k)})^T (\mathbf{A}\mathbf{p}^{(k)} - \mathbf{b})}{(\mathbf{v}^{(k)})^T \mathbf{A}\mathbf{v}^{(k)}}.$$

Ha bevezetjük az

$$\mathbf{r}^{(k)} := \mathbf{b} - \mathbf{A}\mathbf{p}^{(k)} = -\mathbf{v}^{(k)}$$

reziduális vektort, akkor az előbbi képleteket összefoglalhatjuk a következő alakban:

$$\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A}\mathbf{p}^{(k)} \tag{11}$$

$$\alpha_k = \frac{(\mathbf{r}^{(k)})^T \mathbf{r}^{(k)}}{(\mathbf{r}^{(k)})^T \mathbf{A}\mathbf{r}^{(k)}} \tag{12}$$

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} + \alpha_k \mathbf{r}^{(k)}. \tag{13}$$

Példa

A

$$\begin{array}{rclclcl} 4x_1 & + & 2x_2 & - & x_3 & = & 0 \\ 2x_1 & + & 5x_2 & & & = & 8 \\ -x_1 & & & + & 3x_3 & = & 1. \end{array}$$

lineáris egyenletrendszerre alkalmaztuk a gradiens módszert a (11)-(13) rekurzív képletekkel a $\mathbf{p}^{(0)} = (3, 3, 3)^T$ kezdőértékből kiindulva.

Megjegyezzük, hogy a módszer alkalmazható, hiszen a lineáris rendszer együtthatómátrixa szimmetrikus és pozitív definit. A kapott $\mathbf{p}^{(k)}$ sorozat első 13 tagját a következő táblázatban soroltuk fel a közelítés hibájával együtt. Megjegyezzük, hogy a pontos megoldás $(-1, 2, 0)$.

Példa folyt.

Lineáris egyenletrendszer megoldása gradiens módszerrel

k	$\mathbf{p}^{(k)}$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$
0	(3.00000000, 3.00000000, 3.00000000)	5.09901951
1	(0.43469388, 0.77673469, 2.14489796)	2.85575065
2	(0.03799038, 1.89938726, 0.41611180)	1.12280719
3	(-0.59954375, 1.61568290, 0.37817223)	0.67162421
4	(-0.75093609, 1.98854968, 0.13393796)	0.28302529
5	(-0.90321440, 1.90857051, 0.10622765)	0.17032651
6	(-0.93575911, 1.99605148, 0.03257991)	0.07213829
7	(-0.97504377, 1.97631917, 0.02650106)	0.04342696
8	(-0.98365956, 1.99904876, 0.00839916)	0.01839730
9	(-0.99365117, 1.99398134, 0.00679190)	0.01107528
10	(-0.99583018, 1.99975420, 0.00213698)	0.00469196
11	(-0.99837993, 1.99846385, 0.00173029)	0.00282459
12	(-0.99893668, 1.99993749, 0.00054530)	0.00119662
13	(-0.99958687, 1.99960829, 0.00044139)	0.00072037

8.6. Newton-módszer

Most tekintsünk egy $f: \mathbb{R}^n \rightarrow \mathbb{R}$ függvényt. Rögzítsünk egy $\mathbf{p}^{(0)}$ vektort. Ha $f \in C^3$, akkor $\mathbf{p}^{(0)}$ egy környezetében f közelíthető a

$$g(\mathbf{x}) := f(\mathbf{p}^{(0)}) + f'(\mathbf{p}^{(0)})^T (\mathbf{x} - \mathbf{p}^{(0)}) + \frac{1}{2} (\mathbf{x} - \mathbf{p}^{(0)})^T f''(\mathbf{p}^{(0)}) (\mathbf{x} - \mathbf{p}^{(0)}) \quad (14)$$

másodfokú Taylor-polinomjával, ahol $f'(\mathbf{p}^{(0)})$ f gradiensvektora, $f''(\mathbf{p}^{(0)})$ pedig f Hesse-mátrixa $\mathbf{p}^{(0)}$ -ban. Tegyük fel, hogy $f''(\mathbf{p}^{(0)})$ pozitív definit. Ekkor g -nek globális minimuma létezik, amelyet a

$$\mathbf{p}^{(1)} = \mathbf{p}^{(0)} - \left(f''(\mathbf{p}^{(0)}) \right)^{-1} f'(\mathbf{p}^{(0)})$$

pontban vesz fel. Ekkor $\mathbf{p}^{(1)}$ -et tekinthetjük f minimumhelye közelítésének. Ezután megismételjük az eljárást a $\mathbf{p}^{(1)}$ pontbeli Taylor-közelítést használva. Így definiálhatjuk a következő iterációs módszert:

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \left(f''(\mathbf{p}^{(k)}) \right)^{-1} f'(\mathbf{p}^{(k)}) \quad (15)$$

A (15) iterációs módszert **Newton-féle minimumkeresési módszernek** hívjuk.

Könnyen látható, hogy ez azonos az $f'(\mathbf{x}) = \mathbf{0}$ egyenletrendszer megoldására felírt Newton-iterációval. Ebből kapjuk rögtön a következő tételt.

Tétel

Legyen $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^3$, $f'(\mathbf{p}) = \mathbf{0}$ és $\mathbf{f}''(\mathbf{p})$ pozitív definit. Ekkor f -nek $\mathbf{p}$ -ben lokális minimuma van, és a (15) Newton-iteráció lokálisan kvadratikusan konvergál $\mathbf{p}$ -hez.

Példa

Alkalmazzuk a Newton-módszert az $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényre. A $(-1, 4)^T$ pontból indított (15) iteráció első 5 tagját a következő táblázatban tüntettük fel. A sorozat igen gyorsan megközelítette a pontos $(1, 0.5)^T$ minimumhelyet. Megjegyezzük, hogy az $(1, 3)^T$ pontból indított Newton-sorozat egy lépésben már a pontos minimumhelyet adja vissza.

Példa folyt.

Newton-módszer, $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2^2}$
0	(-1.00000000, 4.00000000)	57.00000000	4.03112887	
1	(-1.33333333, 0.83333333)	10.90123457	2.35702260	0.14504754
2	(0.76666667, -1.91111111)	19.55698889	2.42237512	0.43602752
3	(0.80979667, 0.32695523)	0.07235807	0.25714159	0.04382173
4	(0.99964684, 0.48162536)	0.00129935	0.01837803	0.27794212
5	(0.99998771, 0.49998766)	0.00000000	0.00001742	0.05156519

8.7. Kvázi-Newton módszerek

Az előző szakaszhoz hasonlóan közelítsük az f függvényt egy $\mathbf{p}^{(k)}$ pontja környezetében a

$$g(\mathbf{x}) := f(\mathbf{p}^{(k)}) + \left(\mathbf{v}^{(k)}\right)^T (\mathbf{x} - \mathbf{p}^{(k)}) + \frac{1}{2}(\mathbf{x} - \mathbf{p}^{(k)})^T \mathbf{A}^{(k)}(\mathbf{x} - \mathbf{p}^{(k)}) \quad (16)$$

kvadratikus függvénnyel. Ha $\mathbf{v}^{(k)} \approx f'(\mathbf{p}^{(k)})$ és $\mathbf{A}^{(k)} \approx f''(\mathbf{p}^{(k)})$, akkor (16) közelíti f másodfokú $\mathbf{p}^{(k)}$ -körüli Taylor-polinomját, így valóban f közelítésének tekinthető $\mathbf{p}^{(k)}$ egy kis környezetében. Azt várjuk, hogy g minimumhelye közelíteni fogja f minimumhelyét. Ha $\mathbf{A}^{(k)}$ pozitív definit, akkor g minimumhelye a

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \left(\mathbf{A}^{(k)}\right)^{-1} \mathbf{v}^{(k)}. \quad (17)$$

pontban van. Ezeket az iterációs eljárásokat **kvázi-Newton minimumkeresési módszereknek** hívjuk.

Választhatjuk $\mathbf{A}^{(k)}$ -t és $\mathbf{v}^{(k)}$ -t az $f''(\mathbf{p}^{(k)})$ Hesse-mátrix és az $f'(\mathbf{p}^{(k)})$ gradiensvektor numerikus közelítésének: $\mathbf{A}^{(k)} = (a_{ij}^{(k)})$ és

$\mathbf{v}^{(k)} = (v_1^{(k)}, \dots, v_n^{(k)})^T$, ahol

$$a_{ij}^{(k)} = \frac{1}{h^2} \left(f(\mathbf{p}^{(k)} + h\mathbf{e}^{(i)} + h\mathbf{e}^{(j)}) - f(\mathbf{p}^{(k)} + h\mathbf{e}^{(i)}) - f(\mathbf{p}^{(k)} + h\mathbf{e}^{(j)}) + f(\mathbf{p}^{(k)}) \right)$$

és

$$v_i^{(k)} = \frac{1}{h} \left(f(\mathbf{p}^{(k)} + h\mathbf{e}^{(i)}) - f(\mathbf{p}^{(k)}) \right),$$

$i, j = 1, \dots, n$ ($\mathbf{e}^{(i)}$ az i -edik egységvektor, $h > 0$ rögzített kis lépésköz).

Ezzel a módosítással nincs szükség a pontos Jacobi- és Hesse-mátrix ismeretére, viszont minden iterációs lépésben n^2 nagyságrendű függvény kiértékelést kell elvégezni.

Most tekintsük azt az esetet, amikor a (17) képletben $\mathbf{v}^{(k)} = f'(\mathbf{p}^{(k)})$, azaz vizsgáljuk a

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} - \left(\mathbf{A}^{(k)}\right)^{-1} f'(\mathbf{p}^{(k)}) \quad (18)$$

alakú kvázi-Newton módszereket. Feltesszük tehát, hogy a függvény gradiensvektorát ki tudjuk számítani, és a kérdés az, hogyan közelítsük a függvény Hesse-mátrixát. Erre egy lehetőség a Broyden-módszer alkalmazása az $f'(\mathbf{x}) = \mathbf{0}$ egyenletrendszer gyökének meghatározására:

$$\mathbf{A}^{(k)} \mathbf{s}^{(k)} = -f'(\mathbf{p}^{(k)}), \quad (19)$$

$$\mathbf{p}^{(k+1)} = \mathbf{p}^{(k)} + \mathbf{s}^{(k)}, \quad (20)$$

$$\mathbf{y}^{(k)} = f'(\mathbf{p}^{(k+1)}) - f'(\mathbf{p}^{(k)}), \quad (21)$$

$$\mathbf{A}^{(k+1)} = \mathbf{A}^{(k)} + \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)} \mathbf{s}^{(k)})(\mathbf{s}^{(k)})^T}{\|\mathbf{s}^{(k)}\|_2^2}. \quad (22)$$

Példa

Alkalmazzuk a (19)–(22) képletekkel definiált Broyden-módszert az $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényre. A $(2, 2)^T$ pontból indítottuk a sorozatot, az $\mathbf{A}^{(0)}$ mátrix pedig az $f''(2, 2)$ Hesse-mátrix $h = 0.05$ lépésközű másodrendű differencia képlettel számított közelítése volt. A kapott sorozat első 10 tagját a következő táblázatban láthatjuk.

Példa folyt.

Broyden-módszer, $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2}$
0	(2.00000000, 2.00000000)	2.00000e+00	1.80277564	
1	(1.28952043, 0.56127886)	4.59574e-01	0.29593441	0.16415488
2	(1.35039835, 0.89916410)	2.46195e-01	0.53114121	1.79479368
3	(1.24875073, 0.73204681)	1.32833e-01	0.34018032	0.64047058
4	(1.12570322, 0.59780553)	3.67287e-02	0.15927091	0.46819553
5	(1.05911935, 0.54518730)	7.97359e-03	0.07441095	0.46719737
6	(0.99939685, 0.49649610)	3.43894e-05	0.00355544	0.04778109
7	(1.01133354, 0.50962433)	2.69479e-04	0.01486866	4.18194987
8	(1.00464762, 0.50384065)	4.58758e-05	0.00602918	0.40549562
9	(1.00047293, 0.50036811)	4.91375e-07	0.00059931	0.09940111
10	(1.00008014, 0.50006497)	1.37638e-08	0.00010316	0.17213595

A (22) iterációs módszerrel az a probléma, hogy mivel $\mathbf{A}^{(k)}$ az $f''(\mathbf{p})$ Hesse-mátrix közelítése, így természetes megkövetelni, hogy $\mathbf{A}^{(k)}$ pozitív definit legyen minden k -ra. Ez ahhoz is kell, hogy a (16) kvadratikusan függvénynek legyen minimuma minden k -ra. A numerikus tapasztalat is azt támasztja alá, hogy azok a (18) alakú kvázi-Newton módszerek a leghatékonyabbak, ahol $\mathbf{A}^{(k)}$ pozitív definit közelítése a Hesse-mátrixnak. A Broyden-módszerrel generált $\mathbf{A}^{(k)}$ mátrixsorozat viszont pozitív definit mátrixból kiindulva még csak nem is szimmetrikus mátrixokat generál.

Az első célunk ezért úgy módosítani a Broyden-módszer képletét, hogy az szimmetrikus mátrixot generáljon minden k -ra. Tegyük fel, hogy $\mathbf{A}^{(k)}$ szimmetrikus, és legyen

$$\mathbf{B}^{(k+1,1)} = \mathbf{A}^{(k)} + \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})(\mathbf{s}^{(k)})^T}{\|\mathbf{s}^{(k)}\|_2^2}$$

a Broyden-féle iterált mátrix. Megmutatható, hogy egy $\mathbf{A}$ mátrixhoz bizonyos értelemben legközelebbi szimmetrikus mátrix az

$$\frac{1}{2}(\mathbf{A} + \mathbf{A}^T)$$

mátrix. Ezért természetes ötlet $\mathbf{B}^{(k+1,1)}$ -et úgy módosítani, hogy

$$\begin{aligned} \mathbf{B}^{(k+1,2)} &= \frac{1}{2} \left(\mathbf{B}^{(k+1,1)} + \mathbf{B}^{(k+1,1)T} \right) \\ &= \mathbf{A}^{(k)} + \frac{1}{2} \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})(\mathbf{s}^{(k)})^T + \mathbf{s}^{(k)}(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})^T}{\|\mathbf{s}^{(k)}\|_2^2} \end{aligned} \quad (23)$$

legyen.

Ezzel viszont az a gond, hogy $\mathbf{B}^{(k+1,2)}$ nem teljesíti az $\mathbf{A}^{(k+1)}\mathbf{s}^{(k)} = \mathbf{y}^{(k)}$ szelő egyenletet, amely a Broyden-módszer kiindulási ötlete volt. Korrigáljuk ezt a hibát (22) újbóli alkalmazásával: legyen

$$\mathbf{B}^{(k+1,3)} = \mathbf{B}^{(k+1,2)} + \frac{(\mathbf{y}^{(k)} - \mathbf{B}^{(k+1,2)}\mathbf{s}^{(k)})(\mathbf{s}^{(k)})^T}{\|\mathbf{s}^{(k)}\|_2^2}. \quad (24)$$

Ez újra nem szimmetrikus, ezért megismételjük az eljárást: képezzük a $\mathbf{B}^{(k+1,2i)}$ és $\mathbf{B}^{(k+1,2i+1)}$ mátrixokat a sorozat előző tagjából (23) és (24) segítségével $i = 2, 3, \dots$ -re.

Megmutatható, hogy a $\mathbf{B}^{(k+1,i)}$ mátrixsorozat konvergál az

$$\begin{aligned} \mathbf{A}^{(k+1)} = \mathbf{A}^{(k)} &+ \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})(\mathbf{s}^{(k)})^T + \mathbf{s}^{(k)}(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})^T}{\|\mathbf{s}^{(k)}\|_2^2} \\ &- \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{s}^{(k)}\|_2^4} \mathbf{s}^{(k)}(\mathbf{s}^{(k)})^T \end{aligned} \quad (25)$$

szimmetrikus mátrixhoz. Ez egy olyan mátrix korrekciós iteráció, amely megőrzi a mátrix szimmetrikus tulajdonságát, és amely teljesíti az $\mathbf{A}^{(k+1)}\mathbf{s}^{(k)} = \mathbf{y}^{(k)}$ szelő egyenletet. Ezt a mátrix iterációt **Powell-féle szimmetrikus Broyden-iterációnak**, angol rövidítése alapján **PSB-iterációnak** nevezzük.

Tétel

Legyen $f \in C^3$, $f'(\mathbf{p}) = 0$, $f''(\mathbf{p})$ pozitív definit. Ekkor létezik olyan $\varepsilon, \delta > 0$, hogy a (19)–(21), (25) iteráció definiált minden k -ra, és szuperlineárisan konvergál $\mathbf{p}$ -hez, ha $\|\mathbf{p}^{(0)} - \mathbf{p}\|_2 < \varepsilon$ és $\|\mathbf{A}^{(0)} - f''(\mathbf{p})\|_2 < \delta$.

Példa

Ebben a példában a (18) kvázi-Newton módszert a PSB-iterációval alkalmaztuk az $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényre. A korábbi példában használt kezdőértékekből indítva a következő táblázatban felsorolt eredményeket kapjuk. A konvergencia gyorsabb, mint a Broyden-módszernél volt.

Példa folyt.

A (18) kvázi-Newton módszer PSB-iterációval

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2}$
0	(2.00000000, 2.00000000)	2.00000e+00	1.80277564	
1	(1.28952043, 0.56127886)	4.59574e-01	0.29593441	0.16415488
2	(1.25102079, 0.70409379)	1.50630e-01	0.32352080	1.09321792
3	(1.19910219, 0.73444653)	8.02473e-02	0.30758228	0.95073416
4	(1.14966546, 0.69907469)	5.06393e-02	0.24905919	0.80973192
5	(1.00399514, 0.50473229)	3.40491e-05	0.00619320	0.02486638
6	(0.99975498, 0.49938607)	6.64526e-07	0.00066102	0.10673251
7	(1.00003118, 0.49997474)	1.46839e-08	0.00004012	0.06070113
8	(1.00001593, 0.50000889)	7.05953e-10	0.00001824	0.45466117
9	(1.00000627, 0.50000724)	8.24492e-11	0.00000958	0.52515860
10	(1.00000015, 0.50000024)	7.49020e-14	0.00000028	0.02901243

A PSB-iteráció nem teljesíti azt a korábban megfogalmazott célunkat, hogy $\mathbf{A}^{(k)}$ pozitív definit legyen minden k -ra, ha $\mathbf{A}^{(0)}$ pozitív definit. Ha egy $\mathbf{A}$ mátrix pozitív definit, akkor az

$$\mathbf{A} = \mathbf{L}\mathbf{L}^T$$

Cholesky-felbontása létezik, ahol $\mathbf{L}$ nonszinguláris. Fordítva, ha

$$\mathbf{A} = \mathbf{M}\mathbf{M}^T$$

alakú, ahol $\mathbf{M}$ nonszinguláris, akkor $\mathbf{A}$ pozitív definit, hiszen

$$\mathbf{x}^T \mathbf{M}\mathbf{M}^T \mathbf{x} = (\mathbf{M}^T \mathbf{x})^T \mathbf{M}^T \mathbf{x} = \|\mathbf{M}^T \mathbf{x}\|_2^2 \geq 0,$$

és egyenlőség csak akkor van, ha $\mathbf{M}^T \mathbf{x} = \mathbf{0}$, és ezért $\mathbf{x} = \mathbf{0}$.

Legyen

$$\mathbf{A}^{(k)} = \mathbf{M}^{(k)}(\mathbf{M}^{(k)})^T$$

alakú, ahol $\mathbf{M}^{(k)}$ invertálható (de nem feltétlenül alulról trianguláris). A következő Hesse-mátrix közelítést, $\mathbf{A}^{(k+1)}$ -et

$$\mathbf{A}^{(k+1)} = \mathbf{M}^{(k+1)}(\mathbf{M}^{(k+1)})^T$$

alakban keressük, ahol $\mathbf{A}^{(k+1)}$ -től megköveteljük, hogy teljesítse az

$$\mathbf{A}^{(k+1)} \mathbf{s}^{(k)} = \mathbf{y}^{(k)}$$

szelő egyenleteket. A szelő egyenletből következik, hogy

$$(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)} = (\mathbf{s}^{(k)})^T \mathbf{A}^{(k+1)} \mathbf{s}^{(k)},$$

ezért ha $\mathbf{A}^{(k+1)}$ pozitív definit, akkor az

$$(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)} > 0 \tag{26}$$

egyenlőtlenség teljesül. Megmutatjuk, hogy (26) teljesülése esetén a szelő egyenletnek van pozitív definit megoldása.

Vezessük be a $\mathbf{v}^{(k)} := (\mathbf{M}^{(k+1)})^T \mathbf{s}^{(k)}$ jelölést. Ekkor a szelő egyenlet felírható a következőképpen:

$$(\mathbf{M}^{(k+1)})^T \mathbf{s}^{(k)} = \mathbf{v}^{(k)}, \quad (27)$$

$$\mathbf{M}^{(k+1)} \mathbf{v}^{(k)} = \mathbf{y}^{(k)}. \quad (28)$$

Az $\mathbf{M}^{(k+1)}$ mátrixot az $\mathbf{M}^{(k)}$ mátrixot módosítva szeretnénk előállítani, ezért a Broyden-módszer levezetését követve (28) alapján természetes $\mathbf{M}^{(k+1)}$ -et az

$$\mathbf{M}^{(k+1)} = \mathbf{M}^{(k)} + \frac{(\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})(\mathbf{v}^{(k)})^T}{\|\mathbf{v}^{(k)}\|_2^2} \quad (29)$$

alakban keresni. Ekkor $\mathbf{M}^{(k+1)}$ teljesíti a (28) egyenletet, és a legkevesbé tér el $\mathbf{M}^{(k)}$ -től abban az értelemben, hogy

$$\mathbf{M}^{(k+1)} \mathbf{z} = \mathbf{M}^{(k)} \mathbf{z} \quad \text{minden } \mathbf{z} \perp \mathbf{v}^{(k)}\text{-ra.}$$

$\mathbf{M}^{(k+1)}$ -et visszahelyettesítve a (27) egyenletbe kapjuk, hogy

$$\begin{aligned}
\mathbf{v}^{(k)} &= (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} + \frac{((\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})(\mathbf{v}^{(k)})^T)^T}{\|\mathbf{v}^{(k)}\|_2^2} \mathbf{s}^{(k)} \\
&= (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} + \frac{\mathbf{v}^{(k)}(\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})^T}{\|\mathbf{v}^{(k)}\|_2^2} \mathbf{s}^{(k)} \\
&= (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} + \frac{(\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{v}^{(k)}\|_2^2} \mathbf{v}^{(k)}.
\end{aligned}$$

Ebből következik, hogy $(\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} = \alpha \mathbf{v}^{(k)}$ alakú, ahol

$$\begin{aligned}
\alpha &= 1 - \frac{(\mathbf{y}^{(k)} - \mathbf{M}^{(k)} \mathbf{v}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{v}^{(k)}\|_2^2} \\
&= 1 - \frac{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{v}^{(k)}\|_2^2} + \frac{(\mathbf{v}^{(k)})^T (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}}{\|\mathbf{v}^{(k)}\|_2^2} \\
&= 1 - \alpha^2 \frac{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{M}^{(k)} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}} + \alpha,
\end{aligned}$$

és így

$$\begin{aligned}
 \alpha^2 &= \frac{(\mathbf{s}^{(k)})^T \mathbf{M}^{(k)} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}}{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}} \\
 &= \frac{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}}{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}.
 \end{aligned} \tag{30}$$

Mivel a számláló pozitív, hiszen feltettük, hogy $\mathbf{A}^{(k)}$ pozitív definit, ezért α kifejezhető a (30) egyenletből, és

$$\mathbf{v}^{(k)} = \frac{1}{\alpha} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)} = \left(\frac{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}} \right)^{1/2} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}.$$

Ezt visszahelyettesítve a (29) egyenletbe

$$\begin{aligned}
 \mathbf{M}^{(k+1)} &= \mathbf{M}^{(k)} + \frac{(\mathbf{y}^{(k)} - \frac{1}{\alpha} \mathbf{M}^{(k)} (\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}) \frac{1}{\alpha} (\mathbf{s}^{(k)})^T \mathbf{M}^{(k)}}{\frac{1}{\alpha^2} \|(\mathbf{M}^{(k)})^T \mathbf{s}^{(k)}\|_2^2} \\
 &= \mathbf{M}^{(k)} + \alpha \frac{\mathbf{y}^{(k)} (\mathbf{s}^{(k)})^T \mathbf{M}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}} - \frac{\mathbf{A}^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T \mathbf{M}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}}.
 \end{aligned}$$

Kis számolással ebből levezethető, hogy

$$\mathbf{A}^{(k+1)} = \mathbf{A}^{(k)} + \frac{\mathbf{y}^{(k)}(\mathbf{y}^{(k)})^T}{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}} - \frac{\mathbf{A}^{(k)} \mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T \mathbf{A}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{A}^{(k)} \mathbf{s}^{(k)}}. \quad (31)$$

Hátra van még azt megmutatni, hogy az iteráció pozitív definit mátrixot generál. Mivel

$$\mathbf{A}^{(k+1)} = \mathbf{M}^{(k+1)} (\mathbf{M}^{(k+1)})^T,$$

ezért elegendő azt belátni, hogy $\mathbf{M}^{(k+1)}$ invertálható. A feltevés szerint $\mathbf{M}^{(k)}$ pozitív definit, és ezért invertálható. Ha feltesszük, hogy (26) teljesül, akkor $\mathbf{M}^{(k+1)}$ invertálhatóságát könnyen kapjuk a (29) képletből.

A (31) formulát Broyden, Flecher, Goldfarb és Shanno vezették be 1970-ben, ezért **BFGS-iterációnak** nevezzük. Ez a jelenleg ismert legjobb iterációs formula a Hesse-mátrix közelítésére. Az iteráció kezdeti mátrixának vagy $f''(\mathbf{p}^{(0)})$ -t vagy ennek egy másodrendű differencia közelítését célszerű használni. Ha $\mathbf{p}^{(0)}$ elegendően közel van $\mathbf{p}$ -hez, és $f''(\mathbf{p})$ pozitív definit, akkor $f''(\mathbf{p}^{(0)})$, és ezért $\mathbf{A}^{(0)}$ is az lesz.

Végül vizsgáljuk meg, hogy a (26) feltétel milyen megszorítást jelent. A Lagrange-féle középértéktételt és a (20), (21) egyenleteket alkalmazva kapjuk, hogy

$$\begin{aligned} (\mathbf{y}^{(k)})^T \mathbf{s}^{(k)} &= \left(f'(\mathbf{p}^{(k+1)}) - f'(\mathbf{p}^{(k)}) \right)^T (\mathbf{p}^{(k+1)} - \mathbf{p}^{(k)}) \\ &= \sum_{i=1}^n \left(\frac{\partial f_i(\mathbf{p}^{(k+1)})}{\partial x_i} - \frac{\partial f_i(\mathbf{p}^{(k)})}{\partial x_i} \right) (p_i^{(k+1)} - p_i^{(k)}) \\ &= \sum_{i=1}^n \left(\sum_{j=1}^n \frac{\partial^2 f_i(\xi^{(k,i)})}{\partial x_i \partial x_j} (p_j^{(k+1)} - p_j^{(k)}) \right) (p_i^{(k+1)} - p_i^{(k)}). \end{aligned}$$

Ha a $\mathbf{p}^{(k)}$ iteráltak elegendően közel maradnak $\mathbf{p}$ -hez az iteráció közben, akkor $\xi^{(k,i)}$ is $\mathbf{p}$ közelében marad, és ezért f'' folytonossága miatt

$$\begin{aligned} (\mathbf{y}^{(k)})^T \mathbf{s}^{(k)} &\approx \sum_{i=1}^n \left(\sum_{j=1}^n \frac{\partial^2 f_i(\mathbf{p})}{\partial x_i \partial x_j} (p_j^{(k+1)} - p_j^{(k)}) \right) (p_i^{(k+1)} - p_i^{(k)}) \\ &= (\mathbf{p}^{(k+1)} - \mathbf{p}^{(k)})^T f''(\mathbf{p}) (\mathbf{p}^{(k+1)} - \mathbf{p}^{(k)}), \end{aligned}$$

ami pozitív, hiszen $f''(\mathbf{p})$ pozitív definit.

Ez a feltétel tehát, ha a sorozat $\mathbf{p}$ -hez tart, $\mathbf{p}$ közelében teljesülni fog. Természetesen ha (26) nem teljesül, akkor is definiálható a (31) iteráció, csak ekkor $\mathbf{A}^{(k+1)}$ pozitív szemidefinit lesz, nem pozitív definit.

Tétel

Legyen $f \in C^3$, $f'(\mathbf{p}) = 0$, $f''(\mathbf{p})$ pozitív definit. Ekkor létezik olyan $\varepsilon, \delta > 0$, hogy a (19)–(21), (31) iteráció definiált minden k -ra, és szuperlineárisan konvergál $\mathbf{p}$ -hez, ha $\|\mathbf{p}^{(0)} - \mathbf{p}\|_2 < \varepsilon$ és $\|\mathbf{A}^{(0)} - f''(\mathbf{p})\|_2 < \delta$.

Példa

A BFGS-iterációval kaptuk az alábbi táblázatban szereplő sorozatot az $f(x, y) = (x^2 - 2y)^2 + 2(x - 1)^2$ függvényre. Ugyanabból a kezdőértékekből indítottuk a módszert, mint az előző példában.

A (18) kvázi-Newton módszer BFGS-iterációval

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2}$
0	(2.00000000, 2.00000000)	2.00000e+00	1.80277564	
1	(1.28952043, 0.56127886)	4.59574e-01	0.29593441	0.16415488
2	(1.23976784, 0.70438005)	1.31429e-01	0.31505527	1.06461181
3	(1.02721672, 0.49403232)	5.98519e-03	0.02786330	0.08843939
4	(1.00995636, 0.51197836)	2.13820e-04	0.01557595	0.55901316
5	(0.99954439, 0.49921815)	8.41172e-07	0.00090492	0.05809714
6	(1.00000534, 0.50000495)	5.76547e-11	0.00000728	0.00804964
7	(1.00000005, 0.50000002)	9.15800e-15	0.00000005	0.00708494
8	(1.00000000, 0.50000000)	8.60000e-19	0.00000000	0.01827989

Teljes indukcióval ellenőrizhető, hogy a BFGS-módszerrel képzett $\mathbf{A}^{(k)}$ mátrixok $\mathbf{B}^{(k)} := (\mathbf{A}^{(k)})^{-1}$ inverzét a

$$\begin{aligned} \mathbf{B}^{(k+1)} = \mathbf{B}^{(k)} + & \left(1 + \frac{(\mathbf{y}^{(k)})^T \mathbf{B}^{(k)} \mathbf{y}^{(k)}}{(\mathbf{s}^{(k)})^T \mathbf{y}^{(k)}} \right) \frac{\mathbf{s}^{(k)} (\mathbf{s}^{(k)})^T}{(\mathbf{s}^{(k)})^T \mathbf{y}^{(k)}} \\ & - \frac{\mathbf{s}^{(k)} (\mathbf{y}^{(k)})^T \mathbf{B}^{(k)} + \mathbf{B}^{(k)} \mathbf{y}^{(k)} (\mathbf{s}^{(k)})^T}{(\mathbf{s}^{(k)})^T \mathbf{y}^{(k)}} \end{aligned} \quad (32)$$

rekurzív képlettel is kiszámíthatjuk. Ezt az összefüggést használva a (19) egyenlet helyettesíthető az

$$\mathbf{s}^{(k)} = -\mathbf{B}^{(k)} f'(\mathbf{p}^{(k)}) \quad (33)$$

egyenlettel, és így a módszer alkalmazásakor nincs szükség lineáris egyenletrendszer megoldására vagy mátrix invertálásra.

A BFGS-iteráció levezetéséhez hasonlóan kaphatjuk a DFP-iteráció képletét. Újra $\mathbf{A}^{(k+1)} = \mathbf{M}^{(k+1)}(\mathbf{M}^{(k+1)})^T$ alakban keressük a módosított Hesse-közelítést, de a (27)–(28) szelő egyenletek helyett most az azzal ekvivalens

$$\begin{aligned}(\mathbf{M}^{(k+1)})^{-1} \mathbf{y}^{(k)} &= \mathbf{v}^{(k)} \\ \left(\mathbf{M}^{(k+1)T}\right)^{-1} \mathbf{v}^{(k)} &= \mathbf{s}^{(k)}\end{aligned}$$

egyenletekből indulunk ki. Ennek megoldását

$$\left(\mathbf{M}^{(k+1)}\right)^{-1} = \left(\mathbf{M}^{(k)}\right)^{-1} + \frac{\left(\mathbf{s}^{(k)} - (\mathbf{M}^{(k)})^{-1} \mathbf{v}^{(k)}\right) (\mathbf{v}^{(k)})^T}{\|\mathbf{v}^{(k)}\|_2^2}$$

alakban keresve kapjuk, hogy

$$\mathbf{v}^{(k)} = \left(\frac{(\mathbf{y}^{(k)})^T \mathbf{s}^{(k)}}{(\mathbf{y}^{(k)})^T (\mathbf{A}^{(k)})^{-1} \mathbf{y}^{(k)}} \right)^{1/2} (\mathbf{M}^{(k)})^{-1} \mathbf{y}^{(k)},$$

feltéve, hogy a (26) teljesül.

Ebből kiszámítható, hogy

$$\begin{aligned} \mathbf{A}^{(k+1)} = \mathbf{A}^{(k)} &+ \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})(\mathbf{y}^{(k)})^T + \mathbf{y}^{(k)}(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})^T}{(\mathbf{y}^{(k)})^T\mathbf{s}^{(k)}} \\ &- \frac{(\mathbf{y}^{(k)} - \mathbf{A}^{(k)}\mathbf{s}^{(k)})^T\mathbf{s}^{(k)}}{((\mathbf{y}^{(k)})^T\mathbf{s}^{(k)})^2}\mathbf{y}^{(k)}(\mathbf{y}^{(k)})^T. \end{aligned} \quad (34)$$

Ezt a formulát **DFP-iterációnak** nevezzük felfedezői után: Davidon (1959) és Fletcher, Powell (1963).

Ellenőrizhető, hogy a DFP-iterációval generált $\mathbf{A}^{(k)}$ mátrix inverze kiszámítható a következő rekurzív módon:

$$(\mathbf{A}^{(k+1)})^{-1} = (\mathbf{A}^{(k)})^{-1} + \frac{\mathbf{s}^{(k)}(\mathbf{s}^{(k)})^T}{(\mathbf{s}^{(k)})^T\mathbf{y}^{(k)}} - \frac{(\mathbf{A}^{(k)})^{-1}\mathbf{y}^{(k)}(\mathbf{y}^{(k)})^T(\mathbf{A}^{(k)})^{-1}}{(\mathbf{y}^{(k)})^T(\mathbf{A}^{(k)})^{-1}\mathbf{y}^{(k)}}. \quad (35)$$

Példa

A DFP-iterációt vizsgáltuk a korábbi feladatra. Ez a módszer is a BFGS-iterációhoz hasonlóan gyorsan konvergál.

A (18) kvázi-Newton módszer DFP-iterációval

k	$\mathbf{p}^{(k)}$	$f(\mathbf{p}^{(k)})$	$\ \mathbf{p}^{(k)} - \mathbf{p}\ _2$	$\frac{\ \mathbf{p}^{(k)} - \mathbf{p}\ _2}{\ \mathbf{p}^{(k-1)} - \mathbf{p}\ _2}$
0	(2.00000000, 2.00000000)	2.00000e+00	1.80277564	
1	(1.28952043, 0.56127886)	4.59574e-01	0.29593441	0.16415488
2	(1.25682024, 0.70394625)	1.61396e-01	0.32794924	1.10818219
3	(1.09891338, 0.59229507)	2.00977e-02	0.13528576	0.41252041
4	(1.01148073, 0.50204318)	6.24877e-04	0.01166112	0.08619621
5	(1.00103666, 0.50022718)	4.77384e-06	0.00106126	0.09100838
6	(1.00001771, 0.50001111)	8.01068e-10	0.00002090	0.01969409
7	(0.99999976, 0.49999958)	2.45621e-13	0.00000049	0.02332123
8	(1.00000001, 0.50000002)	4.22000e-16	0.00000002	0.03601757